

xv6 及 Labs 课程项目

—— 操作系统课程设计

姓名:	吴瑞翔
学号:	2351716
学院:	计算机科学与技术学院
专业:	软件工程
指导教师:	王冬青

本项目 github 源码托管链接:

<https://github.com/xiangmaster/xv6.git>



同濟大學
TONGJI UNIVERSITY

二〇二五 年 八 月 十 五 日

目录

Lab0: Environment Setup	1
[Tools]	1
[Guidance]	3
Lab1: Utilities	6
[Boot xv6(easy)]	6
[Sleep(easy)]	8
[pingpong[easy]]	11
[primes (moderate)/(hard)]	15
[find (moderate)]	20
[xargs (moderate)]	25
Lab2: System calls	31
[Using gdb(easy)]	31
[System call tracing (moderate)]	36
[Attack xv6 (moderate)]	41
Lab3: Page tables	44
[Inspect a user-process page table (easy)]	44
[Speed up system calls (easy)]	47
[Print a page table (easy)]	50
[Use superpages (moderate)/(hard)]	54
Lab4: Traps	58
[RISC-V assembly (easy)]	58
[Backtrace (moderate)]	63
[Alarm (hard)]	66
Lab5: Copy-on-Write Fork for xv6	74
[Implement copy-on-write fork (hard)]	74
Lab6: networking	81
[NIC (moderate)]	82
[UDP Receive (moderate)]	86
Lab7: Locks	95
[Memory allocator (moderate)]	95
[Buffer Cache(hard)]	101
Lab8: File System	107
[Large files (moderate)]	107
[Symbolic links (moderate)]	111
Lab9: mmap	117
[mmap (hard)]	117

Lab0: Environment Setup

[Tools]

1. 安装 WSL 并启动虚拟化

终端输入命令 `wsl --install` 可安装 Windows Subsystem for Linux。

在 Windows 中，可以访问 `\wsl$` 目录下的所有 WSL 文件。从 Windows，你可以在 "`\wsl$`" 目录下访问所有 WSL 文件。例如 Ubuntu 20.04 安装的 home 目录应该位于：

`"\wsl$\Ubuntu-20.04\home\<username>"`。

启用虚拟化服务，以管理员方式打开 Powershell，输入命令：

```
PS C:\Windows\system32> dism.exe /online /enable-feature /featurename:VirtualMachinePlatform /all /norestart
部署映像服务和管理工具
版本: 10.0.22621.2792
映像版本: 10.0.22631.5472
启用一个或多个功能
[=====100.0%=====]
操作成功完成。
```

下载 X64 的 WSL2 Linux 内核升级包并安装，设置 WSL 默认版本。

```
PS C:\Windows\system32> wsl --set-default-version 2
有关与 WSL 2 关键区别的信息，请访问 https://aka.ms/wsl2
操作成功完成。
```

安装 Ubuntu。

```
xiangmaster@localhost: ~
Provisioning the new WSL instance Ubuntu
This might take a while...
Create a default Unix user account: XiangMaster
Invalid username. A valid username must start with a lowercase letter or underscore,
digits, underscores, and dashes.
Create a default Unix user account: xiangmaster
New password:
Retype new password:
passwd: password updated successfully
To run a command as administrator (user "root"), use "sudo <command>".
See "man sudo_root" for details.
```

```
Welcome to Ubuntu 24.04.2 LTS (GNU/Linux 5.15.167.4-microsoft-standard-WSL2 x86_64)

* Documentation:  https://help.ubuntu.com
* Management:    https://landscape.canonical.com
* Support:        https://ubuntu.com/pro

System information as of Tue Jul  8 11:58:53 CST 2025

System load:  0.03          Processes:           31
Usage of /:   0.1% of 1006.85GB   Users logged in:    0
Memory usage: 5%             IPv4 address for eth0: 100.79.63.123
Swap usage:   0%

* Strictly confined Kubernetes makes edge and IoT secure. Learn how MicroK8s
  just raised the bar for easy, resilient and secure K8s cluster deployment.

https://ubuntu.com/engage/secure-kubernetes-at-the-edge
```

```
This message is shown once a day. To disable it please create the
/home/xiangmaster/.hushlogin file.
xiangmaster@localhost:~$
```

2. 配置 XV6 系统

启动 Ubuntu，根据 <https://pdos.csail.mit.edu/6.828/2020/tools.html> 网站 tools 上的教学指南，在 Ubuntu 终端命令行输入命令一键安装安装 qemu 等所需依赖。

```
sudo apt-get update && sudo apt-get upgrade
```

```
sudo apt-get install git build-essential gdb-multiarch
```

```
qemu-system-misc gcc-riscv64-linux-gnu binutils-riscv64-linux-gnu
```

```
xiangmaster@localhost: ~
xiangmaster@localhost:~$ sudo apt-get install git build-essential gdb-multiarch qemu-system-misc gcc-riscv64-linux-gnu
binutils-riscv64-linux-gnu
[sudo] password for xiangmaster:
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
Package gdb-multiarch is not available, but is referred to by another package.
This may mean that the package is missing, has been obsoleted, or
is only available from another source
```

3. 测试安装

```
xiangmaster@localhost: $ qemu-system-riscv64 --version
QEMU emulator version 8.2.2 (Debian 1:8.2.2+ds-0ubuntu1.7)
Copyright (c) 2003-2023 Fabrice Bellard and the QEMU Project developers
xiangmaster@localhost: $ riscv64-linux-gnu-gcc --version
riscv64-linux-gnu-gcc (Ubuntu 13.3.0-6ubuntu2~24.04) 13.3.0
Copyright (C) 2023 Free Software Foundation, Inc.
This is free software; see the source for copying conditions. There is NO
warranty; not even for MERCHANTABILITY or FITNESS FOR A PARTICULAR PURPOSE.
```

4. 编译内核

下载 xv6 内核源码

```
git clone git://g.csail.mit.edu/xv6-labs-2024
```

更新镜像源

```
sudo nano /etc/apt/sources.list
```

```
sudo apt-get update
```

5. 实验心得体会

xv6 实验环境的搭建不仅是完成后续任务的前提，更是强化实践技能的关键一步。通过亲手安装并配置 RISC-V 工具链、make 等核心开发工具，我深刻体会到一套完整且兼容的工具链对高效开发的重要性。过程中遇到的兼容性和权限问题，促使我深入理解了错误信息，并掌握了有效的排查与解决策略，极大地提升了解决实际系统问题的能力。这些经验为后续深入探索 xv6 内核机制打下了坚实基础，是本次实验最宝贵的收获。

[Guidance]

1. 调试技巧

(1) 如果没通过测试，确保明白为什么代码会失败测试。插入打印语句，直到明白发生了什么。

(2) 在许多情况下，打印语句就足够了，但有时能够单步调试一些汇编代码或检查堆栈上的变量会很有帮助。要用 `gdb` 调试 `xv6`，在一个窗口中运行 `make make qemu-gdb`，在另一个窗口中运行 `gdb`（或 `riscv64-linux-gnu-gdb`），设置一个断点，然后输入 `'c'`（继续），`xv6` 会运行直到它碰到断点。

(3) 如果我们想知道编译器为内核生成的汇编代码，或者想了解内核特定地址上的指令是什么，请查看 `Makefile` 在编译内核时生成的 `kernel.asm` 文件。（`Makefile` 也为所有用户程序生成 `.asm` 文件。）

(4) 如果内核崩溃，它会打印一个错误消息，列出崩溃时程序计数器的值；我们可以搜索 `kernel.asm` 文件，找出程序计数器在崩溃时位于哪个函数中，或者可以运行 `addr2line -e kernel/kernel pc-value`（运行 `man addr2line` 获取详细信息）。如果我们想要获取回溯信息，请使用 `gdb` 重启：在一个窗口中运行 `'make qemu-gdb'`，在另一个窗口中运行 `gdb`（或 `riscv64-linux-gnu-gdb`），在 `panic` 函数中设置断点（`'b panic'`），然后输入 `'c'`（继续）。当内核到达断点时，输入 `'bt'` 获取回溯信息。

(5) 如果内核挂起（例如，由于死锁）或无法继续执行（例如，由于在执行内核指令时发生页错误），我们可以使用 `gdb` 找出它挂起的位置。在一个窗口中运行 `'make qemu-gdb'`，在另一个窗口中运行 `gdb`（`riscv64-linux-gnu-gdb`），然后输入 `'c'`（继续）。当内核似乎挂起时，在 `qemu-gdb` 窗口中按 `Ctrl-C`，并输入 `'bt'` 以获取回溯信息。

(6) `qemu` 具有一个“监控”功能，允许我们查询模拟机的状态。我们可

以通过输入 `control-a c` ("c"代表控制台) 来访问它。一个特别有用的监控命令是 `info mem` 来打印页表。我们可能需要使用 `cpu` 命令来选择 `info mem` 查看哪个核心，或者可以使用 `make CPUS=1 qemu` 启动 `qemu`，以导致只有一个核心。

Lab1: Utilities

本实验将帮助我们熟悉 xv6 及其系统调用。

[Boot xv6 (easy)]

1. 实验目的

利用 WSL 终端切换到 xv6-labs-2024 代码的 util 分支，同时实验 qemu 模拟器启动并运行 xv6 系统，观察实验现象和结果。

2. 实验步骤

在 WSL 终端进入实验目录并且切换到第一个实验分支 util。

```
(base) xiangmaster@localhost: $ cd xv6-labs-2024
(base) xiangmaster@localhost: ~/xv6-labs-2024$ git checkout util
M      Makefile
Already on 'util'
Your branch is up to date with 'origin/util'.
```

构建并运行 xv6

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ make qemu
riscv64-unknown-elf-gcc -Wall -Werror -O -fno-omit-frame-poin
ny -fno-common -nostdlib -fno-builtin-strncpy -fno-builtin-st
memmove -fno-builtin-memcmp -fno-builtin-log -fno-builtin-bze
c -fno-builtin-putc -fno-builtin-free -fno-builtin-memcpy -Wn
n-vprintf -I. -fno-stack-protector -fno-pie -no-pie -c -o u
riscv64-unknown-elf-ld -z max-page-size=4096 -T user/user.ld
intf.o user/umalloc.o
riscv64-unknown-elf-objdump -S user/_xargs > user/xargs.asm
riscv64-unknown-elf-objdump -t user/_xargs | sed '1,/SYMBOL T
mkfs/mkfs fs.img README user/xargstest.sh user/_cat user/_ech
user/_ls user/_mkdir user/_rm user/_sh user/_stressfs user/_u
/_pingpong user/_primes user/_find user/_xargs
nmeta 46 (boot, super, log blocks 30 inode blocks 13, bitmap
balloc: first 968 blocks have been allocated
balloc: write bitmap block at sector 45
qemu-system-riscv64 -machine virt -bios none -kernel kernel/k
egacy=false -drive file=fs.img,if=none,format=raw,id=x0 -devi
xv6 kernel is booting

hart 2 starting
hart 1 starting
init: starting sh
$
```

如果在提示符处输入 ls，会看到类似以下输出：

```
$ ls
.          1 1 1024
..         1 1 1024
README    2 2 2403
xargstest.sh 2 3 93
cat        2 4 35520
echo       2 5 34368
forktest   2 6 16240
grep       2 7 38960
init       2 8 34824
kill       2 9 34296
ln         2 10 34104
ls         2 11 37632
mkdir      2 12 34352
rm         2 13 34344
sh         2 14 57080
stressfs   2 15 35224
usertests  2 16 181136
grind      2 17 50792
wc         2 18 36504
zombie     2 19 33696
sleep      2 20 34184
pingpong   2 21 35048
primes     2 22 35968
find       2 23 37568
xargs      2 24 35416
console    3 25 0
$
```

这些是 `mkfs` 在初始文件系统中包含的文件；大多数是我们可以运行的程序。我们刚刚运行了其中一个：`ls`。

`xv6` 没有 `ps` 命令，但如果你输入 `Ctrl-p`，内核会打印每个进程的信息。现在尝试一下，会看到两行：一行是 `init`，另一行是 `sh`。

```
$
1 sleep  init
2 sleep  sh
```

要退出 `qemu`，请输入：`Ctrl-a x`（同时按下 `Ctrl` 和 `a`，然后按下 `x`）。

3. 实验心得体会

此次实验成功编译并启动了 `xv6` 内核，直观体验了操作系统从引导到 `Shell` 运行的完整流程。通过 `make qemu` 在 `QEMU` 模拟器中运行 `xv6`，并使用 `ls` 命令观察文件系统内容，初步验证了环境搭建的有效性。此外，通过 `Ctrl-p` 了解进程信息，对 `xv6` 的进程管理有了直接感知。整个过程不仅确认了实验环境的就绪，也为后续更复杂的 `xv6` 任务奠定了基础。

[sleep (easy)]

1. 实验目的

本实验的目的是在 xv6 中实现一个用户态的 `sleep` 命令。这个命令需要接收一个命令行参数，该参数代表进程需要暂停的“时钟滴答”数 (ticks)。通过调用 xv6 提供的 `sleep()` 系统调用，使得当前进程暂停指定的时间，然后正常退出。这个实验旨在帮助我们理解如何：

- 编写一个用户态程序。
- 处理命令行参数。
- 调用 xv6 提供的系统调用。
- 将用户态程序编译并集成到 xv6 的文件系统中。

2. 实验步骤

实验源代码：

```
1 #include "kernel/types.h"
2 #include "kernel/stat.h"
3 #include "user/user.h"
4
5 int main(int argc, char *argv[])
6 {
7     // 检查命令行参数的数量
8     if (argc != 2) {
9         fprintf(2, "Error! Need a param.\n"); // 打印错误信息到stderr
10        exit(1);
11    }
12    int ticks = atoi(argv[1]); // 将命令行参数（字符串）转换为整数
13    sleep(ticks); // 调用sleep
14    exit(0);
15 }
```

(1) 创建源文件：在 `user` 目录下创建一个名为 `sleep.c` 的文件。

(2) 编写 `sleep.c`：

- 包含必要的头文件：kernel/types.h、kernel/stat.h、user/user.h。
- 编写 main 函数，其原型为 `int main(int argc, char *argv[])`，用于处理命令行参数。
- 在 main 函数中，首先检查 argc（参数数量）是否为 2。如果不等于 2，说明没有提供时间参数，则调用 `fprintf(2, ...)` 向标准错误（stderr）打印错误信息，并调用 `exit(1)` 退出，表示出错。
- 如果参数数量正确，使用 `atoi()` 函数将 `argv[1]`（一个字符串）转换为整数。`atoi()` 是一个常用的 C 标准库函数，它可以将字符串转换为整数，xv6 也提供了这个函数。
- 调用 `sleep()` 系统调用，并将转换后的整数作为参数传入。
- 最后，调用 `exit(0)` 退出，表示程序正常执行完毕。

(3) 修改 Makefile:

- 打开 xv6 根目录下的 Makefile 文件。
- 在 UPROGS 变量中添加 `_sleep`。这样 `make qemu` 时，编译器就会将 `sleep.c` 编译成可执行文件 `sleep`，并将其打包到 xv6 的文件系统中。

(4) 编译和运行:

- 在 xv6 根目录下，执行 `make qemu` 启动 xv6。
- 在 xv6 shell 中，输入 `sleep 10`，可以看到 shell 暂停了大约一秒钟，然后重新出现提示符。

```
xv6 kernel is booting
hart 2 starting
hart 1 starting
init: starting sh
$ sleep 10
$
```

- 输入 `sleep`，会看到之前我们编写的错误提示信息。

```
$ sleep
Error! Need a param.
```

- 查看正确得分

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ ./grade-lab-util sleep
make: 'kernel/kernel' is up to date.
== Test sleep, no arguments == sleep, no arguments: OK (0.8s)
== Test sleep, returns == sleep, returns: OK (1.0s)
== Test sleep, makes syscall == sleep, makes syscall: OK (0.9s)
```

3. 实验中遇到的问题和解决方法

在实现这个实验的过程中，我主要遇到了两个问题。

首先是不确定如何处理命令行参数，以及如何将字符串参数转换为整数。通过查阅 `xv6` 提供的其他用户程序（`user/echo.c`），我明白了 `main` 函数的 `argv` 参数是一个字符串数组，`argv[1]` 就是用户输入的的第一个参数。然后，通过阅读 `xv6` 的 `user/ulib.c`，我找到了 `atoi()` 函数，它能够将字符串转换为整数，完美解决了我的需求。

其次，为了在参数不正确时向用户提供有用的提示，我需要将错误信息打印到标准错误流，而不是标准输出。通过了解 `Unix-like` 系统中文件描述符的知识，我知道了文件描述符 `2` 代表标准错误，因此我使用了 `fprintf(2, ...)` 来实现这一目的。这些问题的解决过程让我更深入地理解了 `xv6` 的编程环境和惯例。

4. 实验心得体会

这个实验虽然简单，但它提供了一个完整的用户态程序开发流程的实践机会，让我对 xv6 的整体结构和程序开发流程有了基本的掌握。我体会到用户态程序如何通过系统调用与 xv6 内核进行交互，这让我对用户态和内核态之间的界限有了更直观的认识。同时，处理命令行参数是任何实用程序的基础，这个实验巩固了我在这方面的知识。通过简单地修改 Makefile 文件来集成新程序，也让我认识到构建系统在项目开发中的重要性。总的来说，这个实验是一个很好的起点，它帮助我熟悉了 xv6 的开发环境，为后续更复杂的实验打下了坚实的基础。

[pingpong (easy)]

1. 实验目的

本实验的目的是在 xv6 中实现一个用户级程序 pingpong，该程序利用 pipe 系统调用创建一个管道，实现父子进程之间的通信。父进程向子进程发送一个字节，子进程接收到后打印 "ping" 消息，然后向父进程发送一个字节，父进程接收到后打印 "pong" 消息。这个实验旨在帮助我们深入理解：

- fork 系统调用创建新进程。
- pipe 系统调用创建管道进行进程间通信。
- read 和 write 系统调用的使用。
- 进程同步和协作的基本概念。

2. 实验步骤

实验源代码:

```
1 #include "kernel/types.h"
2 #include "kernel/stat.h"
3 #include "user/user.h"
4
5 int main(int argc, char *argv[])
6 {
7     if (argc != 1)
8         // 检查命令行参数个数, 不为1则输出error
9     {
10         fprintf(2, "Error!\n");
11         exit(1);
12     }
13     int p[2];    // 整型数组p存放管道的两个文件描述符
14     pipe(p);    // 创建管道 p[0]表示读, p[1]表示写
15     int pid = fork();
16
17     // 子进程
18     if (pid == 0)
19     {
20         close(p[0]);    // 子进程需要写, 使用关闭读端
21         char tmp = 'x';
22         if (write(p[1], &tmp, 1))
23             fprintf(0, "%d: received ping\n", getpid());
24         // 向标准输出打印消息, 包含子进程PID
25         close(p[1]);
26     }
27
28     // 父进程
29     else
30     {
31         wait((int *)0); // 等待子进程结束
32         close(p[1]);
33         char tmp;
34         if (read(p[0], &tmp, 1))
35             fprintf(0, "%d: received pong\n", getpid());
36         // 向标准输出打印消息, 包含父进程PID
37         close(p[0]);
38     }
39 }
```

(1) 创建源文件：在 `user` 目录下创建一个名为 `pingpong.c` 的文件。

(2) 编写 `pingpong.c`:

- 包含必要的头文件：`kernel/types.h`、`kernel/stat.h`、`user/user.h`。
- 在 `main` 函数中，首先检查命令行参数的数量。这个程序不需要参数，所以 `argc` 应该等于 1。如果参数不正确，则打印错误信息并退出。
- 声明一个整数数组 `p[2]` 用于存储管道的文件描述符。
- 调用 `pipe(p)` 创建管道，调用 `fork()` 创建子进程。
- 子进程逻辑 (`pid == 0`)：关闭管道的读端 `p[0]`，因为它不需要从管道读取。再声明一个字符变量 `tmp`，并赋值为 `'x'`。调用 `write(p[1], &tmp, 1)` 向管道写入一个字节。如果写入成功，则调用 `fprintf(0, "%d: received ping\n", getpid())` 向标准输出打印消息，其中包含子进程的 PID。最后关闭管道的写端 `p[1]`。
- 父进程逻辑 (`pid > 0`)：先调用 `wait((int *)0)` 等待子进程结束。关闭管道的写端 `p[1]`，因为它不需要向管道写入。再声明一个字符变量 `tmp`。调用 `read(p[0], &tmp, 1)` 从管道中读取一个字节。如果读取成功，则调用 `fprintf(0, "%d: received pong\n", getpid())` 向标准输出打印消息，其中包含父进程的 PID。最后关闭管道的读端 `p[0]`。

(3) 修改 `Makefile`:

- 打开 `xv6` 根目录下的 `Makefile` 文件。
- 在 `UPROGS` 变量中添加 `_pingpong`，以便 `make qemu` 时能够

编译该程序。

(4) 编译和运行：

- 在 xv6 根目录下，执行 `make qemu` 启动 xv6。
- 在 xv6 shell 中，输入 `pingpong`，会看到 4: received ping 和 3: received pong 的输出，其中数字是进程的 PID。

```
$ pingpong
4: received ping
3: received pong
```

- 查看正确得分

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ ./grade-lab-util pingpong
make: 'kernel/kernel' is up to date.
== Test pingpong == pingpong: OK (1.7s)
```

3. 实验中遇到的问题和解决方法

在实现这个实验时，我主要遇到了对管道工作原理的理解问题。一开始我没有明确父子进程各自应该使用管道的哪一端。通过查阅 xv6 提供的 `pipe` 系统调用文档，我意识到 `pipe()` 会创建两个文件描述符，`p[0]` 用于读，`p[1]` 用于写。为了避免不必要的资源浪费和潜在的死锁，父子进程应该各自关闭它们不需要的管道端。

<code>int pipe(int p[])</code>	Create a pipe, put read/write file descriptors in <code>p[0]</code> and <code>p[1]</code> .
--------------------------------	---

另一个问题是在父进程中如何等待子进程结束。通过学习 `wait` 系统调用，我了解到它可以使父进程暂停，直到它的一个子进程终止。这保证了父进程在子进程发送数据之前不会尝试读取。最终，我通过正确地关闭文件描述符和使用 `wait` 系统调用，成功地实现了父子进程间的单向通信和基本的同步。

<code>int wait(int *status)</code>	Wait for a child to exit; exit status in <code>*status</code> ; returns child PID.
------------------------------------	--

4. 实验心得体会

pingpong 实验让我对 xv6 中的进程间通信 (IPC) 有了更深刻的理解。通过 fork 和 pipe 的结合使用, 我清晰地看到了父子进程是如何通过一个共享的管道进行数据交换的。这个实验让我体会到, 在多进程环境中进程间的协作和同步的重要性。正确地管理文件描述符, 即关闭不需要的管道端, 是避免资源泄露和程序逻辑错误的关键。wait 系统调用的使用也让我理解了进程生命周期管理的基本机制。整个实验过程让我对 xv6 的系统调用有了更直观的感受, 为后续更复杂的并发和同步实验奠定了坚实的基础。

[primes (moderate)/(hard)]

1. 实验目的

本实验的目的是在 xv6 中实现一个素数筛法程序 primes, 通过创建一系列管道和子进程来模拟 Unix 管道的并行计算。程序将生成从 2 到 280 的所有数字, 并将其通过管道传递给第一个子进程。每个子进程都会从左侧的管道接收数字, 并找到第一个数字作为素数, 然后将这个素数打印出来。接着, 它会将所有不是这个素数倍数的数字通过右侧新创建的管道传递给下一个子进程。这个过程递归地进行, 直到所有数字都被处理完毕。这个实验旨在帮助我们理解:

- fork 和 pipe 系统调用的高级组合使用。
- 如何构建一个进程管道来解决问题。
- 正确管理文件描述符, 避免资源泄露。

- 递归思想在进程创建和通信中的应用。

2. 实验步骤

实验源代码:

```
1 #include "kernel/types.h"
2 #include "kernel/stat.h"
3 #include "user/user.h"
4
5 // 声明 primes 函数, 并使用 __attribute__((noreturn)) 告诉编译器它不会正常返回
6 void primes(int left_pipe_read_fd) __attribute__((noreturn));
7
8 int main(int argc, char *argv[])
9 {
10     int p[2]; // 用于根进程的管道: p[0] 是读取端, p[1] 是写入端
11     int i;
12     // 创建第一个管道, 用于 main 函数向第一个 primes 进程发送数字
13     if (pipe(p) < 0)
14     {
15         fprintf(2, "primes: main pipe failed\n");
16         exit(1);
17     }
18     // 素数筛选
19     if (fork() == 0)
20     {
21         // 子进程: 它将从父进程的管道读取
22         close(p[1]); // 子进程不需要父进程的写入端, 立即关闭
23         primes(p[0]); // 将管道的读取端传递给 primes 函数
24     }
25     else
26     {
27         // 父进程: 负责生成的数字并写入管道
28         close(p[0]); // 父进程不需要读取端, 立即关闭
29         for (i = 2; i <= 280; i++)
30         {
31             if (write(p[1], &i, sizeof(i)) != sizeof(i))
32             {
33                 fprintf(2, "primes: write to pipe failed\n");
34                 exit(1);
35             }
36         }
37         close(p[1]);
38         wait(0); // 父进程等待子进程完成
39         exit(0); // 父进程退出
40     }
41     exit(0);
42 }
43 // primes 函数: 处理素数筛选的递归函数
44 void primes(int left_pipe_read_fd)
45 {
46     int prime; // 当前进程找到的素数
47     int n; // 从左侧管道读取的数字
48     int right_pipe[2]; // 用于当前进程向下一个 primes 进程发送数字的管道
49     int pid;
50     // 从左侧管道读取第一个数字, 这将是当前进程要处理的素数
51     if (read(left_pipe_read_fd, &prime, sizeof(prime)) == 0)
52     {
53         // 如果读取到0字节, 左侧管道已关闭且没有更多数据
54         close(left_pipe_read_fd);
55         exit(0);
56     }
57     fprintf(1, "prime %d\n", prime);
58     // 为下一个 primes 进程创建管道
59     if (pipe(right_pipe) < 0)
60     {
61         fprintf(2, "primes: child pipe failed\n");
62         exit(1);
63     }
64     // 创建子进程来处理剩余的数字
65     pid = fork();
```

```
66     if (pid < 0)
67     {
68         fprintf(2, "primes: fork failed\n");
69         exit(1);
70     }
71
72     if (pid == 0)
73     {
74         // 子进程 (下一个 primes 进程)
75         close(left_pipe_read_fd); // 子进程不需要从其父进程的管道读取 (已经通过 `primes(p[0])` 传递了新的 fd)
76         close(right_pipe[1]);    // 子进程不需要向其自己的写入端写, 它将从 `right_pipe[0]` 读取
77         primes(right_pipe[0]); // 递归调用 primes, 传递新的管道读取端
78     }
79     else
80     {
81         // 父进程 (当前 primes 进程)
82         close(right_pipe[0]); // 父进程不需要从右侧管道读取
83         // 从左侧管道读取剩余的数, 并筛选
84         while (read(left_pipe_read_fd, &n, sizeof(n)) > 0)
85         {
86             if (n % prime != 0)
87             { // 如果数字不是当前素数的倍数
88                 // 将这个数写入到右侧管道, 传递给下一个 primes 进程
89                 if (write(right_pipe[1], &n, sizeof(n)) != sizeof(n))
90                 {
91                     fprintf(2, "primes: write to next pipe failed\n");
92                     exit(1);
93                 }
94             }
95         }
96         close(left_pipe_read_fd); // 所有数字都已从左侧管道读取完毕, 关闭读取端
97         close(right_pipe[1]);    // 所有筛选后的数字都已写入右侧管道, 关闭写入端
98         wait(0);
99         exit(0);
100     }
101 }
```

(1) 创建源文件: 在 `user` 目录下创建一个名为 `primes.c` 的文件。

(2) 编写 `primes.c`:

- 包含必要的头文件: `kernel/types.h`、`kernel/stat.h`、`user/user.h`。
- 声明一个 `primes` 函数, 并使用 `__attribute__((noreturn))` 告诉编译器该函数不会正常返回, 以避免警告。
- `main` 函数: 声明一个整数数组 `p[2]` 作为根进程的管道。

创建管道 `pipe(p)`。再调用 `fork()` 创建第一个子进程。

如果是子进程, 关闭管道的写入端 `p[1]`, 然后调用 `primes(p[0])`, 将管道的读取端传递给它。

如果是父进程, 关闭管道的读取端 `p[0]`, 然后使用 `for` 循环将从 2 到 280 的数字写入管道的写入端 `p[1]`。

在写入完成后，关闭 `p[1]` 并调用 `wait(0)` 等待子进程完成。

- `primes` 函数：接收一个文件描述符 `left_pipe_read_fd` 作为参数。从 `left_pipe_read_fd` 读取第一个数字，将其作为素数 `prime`。如果读取失败（管道为空），则退出。接着打印找到的素数。声明一个新的管道 `right_pipe[2]`，并调用 `pipe(right_pipe)` 创建它。再调用 `fork()` 创建一个新的子进程。

如果是子进程，关闭 `left_pipe_read_fd` 和 `right_pipe[1]`，然后递归调用 `primes(right_pipe[0])`。

如果是父进程，关闭 `right_pipe[0]`，然后使用 `while` 循环从 `left_pipe_read_fd` 读取剩余的数字。

对于每个读取的数字，如果它不是当前素数 `prime` 的倍数，则将其写入 `right_pipe[1]`。

循环结束后，关闭 `left_pipe_read_fd` 和 `right_pipe[1]`，并调用 `wait(0)` 等待子进程完成。

(3) 修改 Makefile:

- 打开 `xv6` 根目录下的 `Makefile` 文件。
- 在 `UPROGS` 变量中添加 `_primes`，以便 `make qemu` 时能够编译该程序。

(4)编译和运行:

- 在 `xv6` 根目录下，执行 `make qemu` 启动 `xv6`。
- 在 `xv6 shell` 中，输入 `primes`，会看到从 2 到 280 之间的所有素数被依次打印出来。

```
$ primes
prime 2
prime 3
prime 5
prime 7
prime 11
prime 13
prime 17
prime 19
prime 23
prime 29
prime 31
prime 37
prime 41
prime 43
prime 47
prime 53
prime 59
prime 61
prime 67
prime 71
prime 73
prime 79
```

- 查看正确得分

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ ./grade-lab-util primes
make: 'kernel/kernel' is up to date.
== Test primes == primes: OK (2.2s)
```

3. 实验中遇到的问题和解决方法

在实现这个实验时，我遇到的最大挑战是对管道和文件描述符的管理。由于这是一个递归的进程管道，每个子进程都需要创建自己的管道并传递给下一个子进程，导致文件描述符的数目会不断增加。如果不及时关闭不需要的文件描述符，xv6 可能会因为文件描述符资源耗尽而崩溃。我的解决方法是在每次 fork 之后，父子进程都立即关

闭它们不需要的管道端。例如，父进程在向子进程传递读端后，会关闭自己的读端。递归调用的子进程在创建新的管道后，也会关闭其父进程传递过来的读端，因为它已经将新的读端传递给了它的子进程。这种精细的文件描述符管理保证了程序能够正常运行，不会耗尽系统资源。另一个问题是如何判断管道的输入已结束，我通过检查 `read` 系统调用的返回值，当它返回 0 时，说明管道的写入端已经关闭且没有更多数据，从而结束了 `primes` 进程。

4. 实验心得体会

`primes` 实验是一个极具挑战性和教育意义的实验。它让我对 `fork` 和 `pipe` 的组合使用有了全新的认识。通过构建一个进程管道，我深刻地理解了 Unix-like 系统中进程间通信的强大之处。通过这个实验，我学会了如何以一种并行和递归的方式思考问题，将一个复杂任务分解成多个可以协作的小任务，并利用 `xv6` 的系统调用来协调它们。正确地管理文件描述符，理解管道的生命周期，以及利用 `read` 的返回值来判断通信结束，这些都成为了我宝贵的经验。这个实验不仅锻炼了我的编程能力，更让我对 `xv6` 的设计思想和操作系统原理有了更深刻的理解。

[find (moderate)]

1. 实验目的

本实验的目的是在 xv6 中实现一个简单的 find 工具，它能够在 一个指定的目录树中，递归地查找所有与给定文件名匹配的文件或目录，并打印出它们的完整路径。这个实验旨在帮助我们理解：

- 如何读取和遍历目录。
- stat 和 fstat 系统调用的使用，以获取文件的类型和状态。
- 递归思想在处理树形结构（如目录树）中的应用。
- 如何正确拼接路径和管理字符串。

2. 实验步骤

实验源代码：

```
1 #include "kernel/types.h"
2 #include "kernel/stat.h"
3 #include "user/user.h"
4 #include "kernel/fs.h" // 包含 struct dirent 和 DIRSIZ 定义
5
6 // 递归查找指定文件名的函数
7 // path: 当前搜索的目录路径
8 // target_name: 要查找的文件名
9 void find(char *path, char *target_name)
10 {
11     char buf[512], *p;
12     int fd;
13     struct dirent de; // 目录项
14     struct stat st;   // 文件状态
15     // 打开当前路径
16     if ((fd = open(path, 0)) < 0)
17     {
18         fprintf(2, "find: 无法打开 %s\n", path);
19         return;
20     }
21     // 获取文件状态
22     if (fstat(fd, &st) < 0)
23     {
24         fprintf(2, "find: 无法获取 %s 的状态\n", path);
25         close(fd);
26         return;
27     }
28     if (st.type != T_DIR)
29     {
```



```
30 // 如果不是目录，检查是否是目标文件本身
31 // 从路径中提取文件名部分进行比较
32 char *file_name_ptr = path;
33 for (char *s = path; *s; s++)
34 {
35     if (*s == '/')
36     {
37         file_name_ptr = s + 1;
38     }
39 }
40 if (strcmp(file_name_ptr, target_name) == 0)
41 {
42     fprintf(1, "%s\n", path); // 匹配成功，打印路径
43 }
44 close(fd);
45 return;
46 }
47
48 // 目录处理：准备缓冲区以拼接子路径 (path + '/' + de.name + '\0')
49 if (strlen(path) + 1 + DIRSIZ + 1 > sizeof(buf))
50 {
51     fprintf(2, "find: 路径过长\n");
52     close(fd);
53     return;
54 }
55 strcpy(buf, path);
56 p = buf + strlen(buf);
57 *p++ = '/';
58 // 遍历目录项
59 while (read(fd, &de, sizeof(de)) == sizeof(de))
60 {
61     if (de.inum == 0)
62         continue; // 跳过未使用的目录项
63
64     // 避免 '.' 和 '..' 造成的无限递归
65     if (strcmp(de.name, ".") == 0 || strcmp(de.name, "..") == 0)
66         continue;
67     // 将目录项名称拼接到缓冲区，形成新的完整路径
68     memmove(p, de.name, DIRSIZ);
69     p[DIRSIZ] = 0; // 确保字符串以空字符结尾
70     // 获取子路径的文件状态
71     if (stat(buf, &st) < 0)
72     {
73         fprintf(2, "find: 无法获取 %s 的状态\n", buf);
74         continue;
75     }
76     if (st.type == T_FILE)
77     {
78         // 如果是文件，比较其名称
79         if (strcmp(de.name, target_name) == 0)
80         {
81             fprintf(1, "%s\n", buf); // 匹配成功，打印完整路径
```

```
82     }
83     }
84     else if (st.type == T_DIR)
85     {
86         // 如果是子目录, 递归调用 find
87         find(buf, target_name);
88     }
89 }
90 close(fd); // 关闭目录文件描述符
91 }
92
93 int main(int argc, char *argv[])
94 {
95     // 检查参数数量: 程序名、起始路径、目标文件名
96     if (argc != 3)
97     {
98         fprintf(2, "用法: find <路径> <文件名>\n");
99         exit(1);
100    }
101
102    // 调用查找函数
103    find(argv[1], argv[2]);
104    exit(0);
105 }
```

(1) 创建源文件: 在 user 目录下创建一个名为 find.c 的文件。

(2) 编写 find.c:

- 包含必要的头文件: kernel/types.h、kernel/stat.h、user/user.h、kernel/fs.h。
- 编写 find 递归函数, 其原型为 void find(char *path, char *target_name)。该函数首先使用 open 打开给定路径 path, 然后用 fstat 获取其文件状态。如果 path 不是目录, 则从路径中提取文件名部分并与 target_name 进行比较, 如果匹配则打印完整路径。如果是目录, 函数会准备一个缓冲区 buf 用于拼接子路径, 并使用 read 循环读取目录项。在循环中, 它会跳过 . 和 .. 目录, 然后将目录项名称拼接到 buf 中。接着, 它会使用 stat 获取子路径的文件状态。如果子路径是文件, 就比较其名称是否与 target_name 匹配, 匹配则打

印路径。如果子路径是目录，就递归调用 `find` 函数。循环结束后，函数会关闭文件描述符。

- 编写 `main` 函数，它负责检查命令行参数数量。如果 `argc` 不等于 3，则打印用法提示并退出。否则，它将调用 `find(argv[1], argv[2])` 开始搜索。

(3) 修改 Makefile:

- 打开 `xv6` 根目录下的 `Makefile` 文件。
- 在 `UPROGS` 变量中添加 `_find`，以便 `make qemu` 时能够编译该程序。

(4) 编译和运行:

- 在 `xv6` 根目录下，执行 `make qemu` 启动 `xv6`。
- 在 `xv6 shell` 中，创建一些目录和文件，然后输入 `find . b`，会看到所有名为 `b` 的文件或目录的完整路径被打印出来。

```
init: starting sh
$ echo > b
$ mkdir a
$ echo > a/b
$ mkdir a/aa
$ echo > a/aa/b
$ find . b
./b
./a/b
./a/aa/b
$
```

- 查看正确得分

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ ./grade-lab-util find
make: 'kernel/kernel' is up to date.
== Test find, in current directory == find, in current directory: OK (1.0s)
== Test find, in sub-directory == find, in sub-directory: OK (0.8s)
== Test find, recursive == find, recursive: OK (1.2s)
```

3. 实验中遇到的问题和解决方法

在实现这个实验时，我主要遇到的挑战是如何正确处理路径和递归逻辑。首先是如何拼接路径，我通过创建一个足够大的缓冲区，并使用 `strcpy` 和 `memmove` 来安全地构建新路径，确保新路径以 `/` 分隔且以空字符结尾。其次是如何避免无限递归，通过跳过目录项 `.` 和 `..`，我成功地防止了程序在当前目录和父目录之间陷入循环。另一个问题是如何将一个文件的完整路径拆分出文件名部分，我通过一个循环遍历路径字符串，找到最后一个 `/` 字符，其后的内容就是文件名。这个逻辑在 `find` 函数处理非目录文件时非常关键。通过细致地处理这些字符串和路径相关的逻辑，我确保了程序的正确性和健壮性。

4. 实验心得体会

`find` 实验让我对 `xv6` 的文件系统结构和相关系统调用有了更深入的理解。我学会了如何通过 `open`、`read` 和 `stat` 等系统调用来遍历一个目录树，这与我们在高级语言中直接使用文件库有很大的不同。递归是解决这类问题的核心思想，通过将大问题分解为与自身相似的小问题，我能够以一种优雅而高效的方式遍历整个目录树。这个实验也让我更加重视文件描述符的管理，例如在函数退出前关闭 `fd`，以避免资源泄露。总的来说，这个实验让我从底层角度理解了目录和文件的组织方式，并锻炼了我的递归编程和资源管理能力，为我后续学习操作系统中更复杂的文件系统概念打下了坚实的基础。

[xargs (moderate)]

1. 实验目的

本实验的目的是在 xv6 中实现一个简化的 `xargs` 命令。`xargs` 从标准输入读取行数据，然后将每一行作为额外参数追加到其自身的命令行参数中，最后执行指定的命令。这个实验旨在帮助我们理解：

- 如何从标准输入逐行读取数据。
- `fork` 和 `exec` 系统调用的组合使用。
- 如何构建一个完整的命令行参数列表并传递给 `exec`。
- 父子进程之间的基本同步。
- 如何实现一个管道的消费者。

2. 实验步骤

实验源代码：

```
1 #include "kernel/types.h"
2 #include "kernel/param.h" // 包含 MAXARG 定义
3 #include "user/user.h"
4
5 #define MAX_LINE_LEN 512 // 每行输入的最大长度
6
7 int main(int argc, char *argv[])
8 {
9     char *cmd_args[MAXARG]; // 存储最终执行命令的参数列表
10    char line_buf[MAX_LINE_LEN]; // 缓存从标准输入读取的一行数据
11    int i, n;
12    int line_len = 0; // 当前行缓冲区已填充的长度
13
14    // 复制 xargs 自身的命令行参数到 cmd_args。
15    // argv[0] 是 "xargs", argv[1] 是实际要执行的命令名。
16    // cmd_args[0] 将是命令名, cmd_args[1]... 是其固定参数。
17    for (i = 1; i < argc; i++)
18    {
19        cmd_args[i - 1] = argv[i];
20    }
21    // cmd_args[argc - 1] 将是为 stdin 行数据保留的位置
22    while ((n = read(0, &line_buf[line_len], 1)) > 0)
23    {
24        if (line_buf[line_len] == '\n')
25        {
26            line_buf[line_len] = 0; // 终止当前行字符串
```

```
27
28     // 将当前行作为额外参数追加到命令参数列表
29     cmd_args[argc - 1] = line_buf;
30     cmd_args[argc] = 0; // 参数列表必须以 NULL 结尾
31
32     // 创建子进程并执行命令
33     if (fork() == 0)
34     {
35         exec(cmd_args[0], cmd_args);
36         fprintf(2, "xargs: exec 失败\n"); // exec 失败说明命令无法执行
37         exit(1);
38     }
39     else
40     {
41         wait(0); // 父进程等待子进程完成
42     }
43     line_len = 0; // 重置缓冲区，准备读取下一行
44 }
45 else
46 {
47     line_len++;
48     if (line_len >= MAX_LINE_LEN)
49     {
50         // 行太长，超出缓冲区限制
51         fprintf(2, "xargs: 行过长\n");
52         exit(1);
53     }
54 }
55 }
56 // 处理最后一行可能没有换行符的情况
57 if (line_len > 0)
58 {
59     line_buf[line_len] = 0;
60     cmd_args[argc - 1] = line_buf;
61     cmd_args[argc] = 0;
62
63     if (fork() == 0)
64     {
65         exec(cmd_args[0], cmd_args);
66         fprintf(2, "xargs: exec 失败\n");
67         exit(1);
68     }
69     else
70     {
71         wait(0);
72     }
73 }
74 exit(0);
75 }
```

(1) 创建源文件：在 user 目录下创建一个名为 xargs.c 的文件。

(2) 编写 xargs.c:

- 包含必要的头文件：kernel/types.h、kernel/param.h、user/user.h。

- 在 `main` 函数中，首先声明一个 `char *cmd_args[MAXARG]` 数组，用于存储最终要执行的命令及其参数。

- 使用一个 `for` 循环，将 `xargs` 自身的命令行参数 (`argv`) 复制到 `cmd_args` 中，例如 `argv[1]` (要执行的命令名) 会成为 `cmd_args[0]`，以此类推。

- 进入一个 `while` 循环，使用 `read(0, ...)` 从标准输入 (文件描述符 0) 逐个字节读取数据。

- 如果读取到换行符 `'\n'`，说明一行结束。将该行数据作为字符串追加到 `cmd_args` 参数列表的末尾。然后，使用 `fork()` 创建一个子进程，在子进程中调用 `exec` 执行命令。父进程则调用 `wait(0)` 等待子进程完成，然后重置行缓冲区。

- 如果读取的不是换行符，则继续将字节存储到行缓冲区中，并检查是否超过最大行长度。

- 在 `while` 循环结束后，需要处理可能存在的最后一行没有以换行符结尾的情况。这个逻辑与循环中的处理类似，同样是构建参数列表，`fork` 子进程并 `exec`，然后 `wait`。

- 最后，调用 `exit(0)` 退出程序。

(3) 修改 Makefile:

- 打开 `xv6` 根目录下的 `Makefile` 文件。

- 在 `UPROGS` 变量中添加 `_xargs`，以便 `make qemu` 时能够编译该程序。

(4) 编译和运行:

- 在 `xv6` 根目录下，执行 `make qemu` 启动 `xv6`。
- 在 `xv6 shell` 中，尝试运行 `echo hello too | xargs echo bye`，会看到预期的输出。

```
$ echo hello too | xargs echo bye
bye hello too
$
```

- 运行 `xargstest.sh` 脚本来测试实现。

```
init: starting sh
$ sh < xargstest.sh
$ $ $ $ $ $ hello
hello
hello
$ $
```

- 查看正确得分

```
(base) xiangmaster@localhost: /xv6-labs-2024$ ./grade-lab-util xargs
make: 'kernel/kernel' is up to date.
== Test xargs == xargs: OK (2.4s)
== Test xargs, multi-line echo == xargs, multi-line echo: OK (0.6s)
```

3. 实验中遇到的问题和解决方法

在实现这个实验时，我遇到的主要问题是如何正确地构建和管理 `exec` 函数所需的参数列表。`exec` 需要一个以 `NULL` 结尾的 `char*` 数组。首先，我通过一个循环将 `xargs` 接收到的固定参数复制到 `cmd_args` 中。然后，对于从标准输入读取的每一行，我需要将其作为新的字符串追加到 `cmd_args` 的末尾。关键在于，我不能直接将 `line_buf` 的地址追加到数组，因为 `line_buf` 会在每次循环中被复用，导致所有行的参数都指向同一块内存。正确的做法是在每次处理一行时，都将 `line_buf` 的地址赋值给 `cmd_args` 的相应位置，并在 `exec` 之后，父进程等待子进程结束后再重置缓冲区。此外，我还特别注意

了处理最后一行没有换行符的情况，因为 `read` 会返回 0，循环结束，但缓冲区中可能还有数据需要处理。我通过在循环后增加一个额外的判断和处理逻辑，确保了所有输入都能被正确处理。

4. 实验心得体会

`xargs` 实验让我对 `xv6` 的进程管理和系统调用有了更深层次的理解。通过将 `fork`、`exec` 和 `wait` 系统调用结合起来，我实现了一个功能强大的工具，它能够将管道输出作为另一个命令的参数。`xargs` 作为一个管道的消费者，完美地演示了如何将一个程序的输出作为另一个程序的输入。此外，这个实验还锻炼了我的 C 语言字符串和数组操作能力，特别是如何动态地构建和传递参数列表。正确地管理内存、处理边界条件（如空行、长行和无换行符的结尾）对于程序的健壮性至关重要。总的来说，这个实验不仅加深了我对 `xv6` 系统调用的理解，也让我掌握了编写实用命令行工具所需的关键技能。

Lab1 得分：

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ ./grade-lab-util
make: 'kernel/kernel' is up to date.
== Test sleep, no arguments == sleep, no arguments: OK (1.0s)
== Test sleep, returns == sleep, returns: OK (1.1s)
== Test sleep, makes syscall == sleep, makes syscall: OK (0.8s)
== Test pingpong == pingpong: OK (1.1s)
== Test primes == primes: OK (1.6s)
== Test find, in current directory == find, in current directory: OK (0.9s)
== Test find, in sub-directory == find, in sub-directory: OK (1.0s)
== Test find, recursive == find, recursive: OK (1.2s)
== Test xargs == xargs: OK (1.4s)
== Test xargs, multi-line echo == xargs, multi-line echo: OK (0.5s)
== Test time ==
time: OK
Score: 110/110
```

Lab2: System calls

本实验将为 xv6 添加一些新的系统调用。

切换至 syscall 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git fetch
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout syscall
Already on 'syscall'
Your branch is up to date with 'origin/syscall'.
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img .gdbinit __pycache__ xv6.out* \
ph barrier
```

[Using gdb(easy)]

1. 实验目的

本实验的目的是学习如何使用 GDB 调试器来调试 xv6 内核。通过设置断点、查看寄存器、检查堆栈回溯等操作，理解 GDB 的基本使用方法，并利用这些工具来回答与 xv6 内核运行状态和崩溃原因相关的问题。

2. 实验步骤

- 启动带 GDB 调试的 make qemu（在第一个终端）

```
make qemu-gdb
```

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ make qemu-gdb
riscv64-unknown-elf-gcc -c -o kernel/entry.o kernel/entry.S
riscv64-unknown-elf-gcc -Wall -Werror -O -fno-omit-frame-pointer -g
```

- 在第二个终端启动 GDB 并加载内核

```
gdb-multiarch kernel/kernel
```



```
(base) xiangmaster@localhost: /xv6-labs-2024$ gdb-multiarch kernel/kernel
GNU gdb (Ubuntu 15.0.50.20240403-0ubuntu1) 15.0.50.20240403-git
Copyright (C) 2024 Free Software Foundation, Inc.
License GPLv3+: GNU GPL version 3 or later <http://gnu.org/licenses/gpl.html>
This is free software: you are free to change and redistribute it.
There is NO WARRANTY, to the extent permitted by law.
Type "show copying" and "show warranty" for details.
This GDB was configured as "x86_64-linux-gnu".
Type "show configuration" for configuration details.
For bug reporting instructions, please see:
<https://www.gnu.org/software/gdb/bugs/>.
Find the GDB manual and other documentation resources online at:
<http://www.gnu.org/software/gdb/documentation/>.

For help, type "help".
Type "apropos word" to search for commands related to "word"...
Reading symbols from kernel/kernel...
warning: File "/home/xiangmaster/xv6-labs-2024/.gdbinit" auto-loading has been declined by your
t to "$debugdir:$datadir/auto-load".
To enable execution of this file add
  add-auto-load-safe-path /home/xiangmaster/xv6-labs-2024/.gdbinit
line to your configuration file "/home/xiangmaster/.config/gdb/gdbinit".
To completely disable this security protection add
  set auto-load safe-path /
line to your configuration file "/home/xiangmaster/.config/gdb/gdbinit".
For more information about this security protection see the
"Auto-loading safe path" section in the GDB manual.  E.g., run from the shell:
  info "(gdb)Auto-loading safe path"
(gdb)
```

- 连接到 qemu

target remote localhost:26000

```
(gdb) target remote localhost:26000
Remote debugging using localhost:26000
0x0000000000000100 in ?? ()
(gdb)
```

- 设置断点

b syscall # 设置 syscall1 函数断点

c # 继续执行内核

```
(gdb) b syscall
Breakpoint 1 at 0x80001c72: file kernel/syscall.c, line 133.
(gdb) c
Continuing.
[Switching to Thread 1.2]

Thread 2 hit Breakpoint 1, syscall () at kernel/syscall.c:133
133 {
(gdb)
```

- 栈回溯分析：通过 backtrace 确定调用 syscall 的函数

layout src

backtrace

```

kernel/syscall.c
126 SYS_link      sys_link,
127 SYS_mkdir     sys_mkdir,
128 SYS_close     sys_close,
129 };
130
131 void
132 syscall(void)
B+> 133 {
134     int num;
135     struct proc *p = myproc();
136
137     num = p->trapframe->a7;
138     if (num > 0 && num < NELEM(syscalls) && syscalls[num]) {
139         // Use num to lookup the system call function for num, call it,
140         // and store its return value in p->trapframe->a0
141         p->trapframe->a0 = syscalls[num]();
142     } else {
remote Thread 1.1 (src) In: syscall                               L133  PC: 0x80001c72
(gdb) backtrace
#0  syscall () at kernel/syscall.c:133
#1  0x0000000080001a2e in usertrap () at kernel/trap.c:67
#2  0x0000000000000000 in ?? ()
Backtrace stopped: frame did not save the PC
(gdb)
  
```

• 栈帧信息显示如下，回溯结果 backtrace 显示 syscall 函数由 usertrap() 函数调用

```

(gdb) backtrace
#0  syscall () at kernel/syscall.c:133
#1  0x0000000080001a2e in usertrap () at kernel/trap.c:67
#2  0x0000000000000000 in ?? ()
Backtrace stopped: frame did not save the PC
(gdb)
  
```

• 单步 n 执行过 struct proc *p = myproc(); 后，使用 p/x *p 查看进程结构体，p->trapframe->a7 的值为 0x1，该值表示系统调用号，用于内核识别用户请求的具体系统调用。

```

(gdb) p /x *p
$1 = {lock = {locked = 0x0, name = 0x800071c8, cpu = 0x0}, state = 0x4, chan = 0x0, killed = 0x0, xstate = 0x0,
pid = 0x1, parent = 0x0, kstack = 0x3fffffd000, sz = 0x1000, pagetable = 0x87f55000, trapframe = 0x87f56000,
context = {ra = 0x800012ae, sp = 0x3fffffd000, s0 = 0x3fffffd000, s1 = 0x80007d60, s2 = 0x80007930, s3 = 0x1,
s4 = 0x8000dbe8, s5 = 0x3, s6 = 0x80018a00, s7 = 0x1, s8 = 0x80018b28, s9 = 0x4, s10 = 0x0, s11 = 0x0}, ofile = {
0x0 <repeats 16 times>}, cwd = 0x80015e70, name = {0x69, 0x6e, 0x69, 0x74, 0x63, 0x6f, 0x64, 0x65, 0x0, 0x0, 0x0,
0x0, 0x0, 0x0, 0x0, 0x0}}
  
```

• 通过 p/x \$sstatus 查看特权寄存器，SPP 位（第 8 位）为 0，表明 CPU 之前处于用户模式（User mode）。

```

(gdb) p /x $sstatus
$2 = 0x200000022
  
```

• 修改 syscall 函数触发内核崩溃

```
//num = p->trapframe->a7;  
num = * (int *) 0;
```

- 内核崩溃 make qemu 调试结果:

```
xv6 kernel is booting  
  
hart 1 starting  
hart 2 starting  
scause=0xd sepc=0x80001c82 stval=0x0  
panic: kerneltrap
```

- 崩溃时的汇编指令: 通过 spec 查询

```
//num = p->trapframe->a7;  
num = * (int *) 0;  
80001c82: 00002683          lw  a3,0(zero) # 0 <_entry-0x80000000>
```

- 触发崩溃的进程名称为 initcode, PID 为 1

3. 实验中遇到的问题和解决方法

我在执行 `make qemu-gdb` 后, GDB 提示会“Connection refused”。当检查是否同时启动了多个 `qemu` 实例后, 关闭所有实例后重新执行即可; 确保 `kernel/Makefile` 中 `GDBPORT` 未被占用。

此外我遇到 `backtrace` 只显示部分栈帧, 无法看到 `usertrap()`。这时可以确保内核编译时开启了调试信息 (`Makefile` 中包含 `-g` 选项), 重新执行 `make clean && make`。

4. 实验心得体会

Using GDB 实验让我深刻体会到了调试工具在操作系统开发中的重要性。不同于用户态程序的调试, 内核调试需要我们更深入地理解底层硬件架构和特权模式。通过这个实验, 我学会了如何使用 GDB

来检查寄存器状态、查看内存内容、跟踪函数调用栈，这些都是定位内核问题不可或缺的技能。我认识到，即使是像 xv6 这样的小型内核，其内部状态也相当复杂，如果没有 GDB 这样的工具，几乎不可能有效地进行故障排除。

5. 实验问题回答

(1) 查看回溯输出，哪个函数调用了 `syscall` ?

—— `usertrap()`

(2) `p->trapframe->a7` 的值是什么，这个值代表什么？（提示：查看 `user/initcode.S`，第一个用户程序 `xv6` 启动。）

—— 值为系统调用号（如 `0x1`），代表用户请求的系统调用类型

(3) CPU 之前处于什么模式？

—— 用户模式（通过 `sstatus` 寄存器的 `SPP` 位判断）

(4) 记下内核在 `panic` 时所在的汇编指令。哪个寄存器对应变量 `num` ?

—— `lw a5, 0(zero)`，变量 `num` 对应 `a5` 寄存器

(5) 为什么内核崩溃？提示：查看文本中的图 3-3；地址 `0` 是否映射在内核地址空间中？上面的 `scause` 值是否确认了这一点？（参见 RISC-V 特权指令的 `scause` 描述）

—— 地址 `0x0` 未在内核地址空间中映射，触发加载页错误（`scause=0xd`）

(6) 内核 `panic` 时正在运行哪个进程的名称是什么？它的进程 ID（`pid`）是什么？

—— 名称为 initcode, PID 为 1

[System call tracing (moderate)]

1. 实验目的

本实验的目的是在 xv6 内核中添加一个系统调用追踪功能。我们将实现一个新的 `trace` 系统调用，它接收一个整数“掩码”作为参数，该掩码的每一位对应一个系统调用号。当这个掩码中某个系统调用号的位被设置时，该系统调用在执行即将返回时，xv6 内核会打印一行信息，包含进程 ID、系统调用名称和返回值。此外，`trace` 系统调用应使其调用者及其后续创建的所有子进程都启用追踪功能，而不会影响其他无关进程。这个实验旨在加深我们对 xv6 系统调用机制、进程状态管理以及内核调试的理解。

2. 实验步骤

(1) 在 Makefile 的 UPROGS 变量中添加 `$U/_trace\`

(2) 添加系统调用接口

- 在 `user/user.h` 中添加函数原型

```
int trace(int);
```

- 在 `user/usys.pl` 中添加系统调用存根

```
entry("trace");
```

- 在 `kernel/syscall.h` 中添加系统调用编号

```
#define SYS_trace 22
```

(3) 实现内核中的 sys_trace()

- 在 kernel/sysproc.c 中添加:

```
1 uint64
2 sys_trace(void)
3 {
4     int mask;
5     argint(0, &mask);
6     myproc()->trace_mask = mask;
7     return 0;
8 }
```

- 在 kernel/syscall.c 的 syscalls 数组中添加:

```
1 extern uint64 sys_trace(void); // 声明 sys_trace 函数
2 static uint64 (*syscalls[])(void) = {
3     ...
4     [SYS_trace]    sys_trace,
5 };
```

(4) 修改进程结构体和 fork()

- 在 kernel/proc.h 的 struc proc 中添加 trace_mask

```
1 struct proc {
2     ...
3     int trace_mask;
4 };
```

- 在 kernel/proc.c 的 fork 中复制掩码

```
1 int
2 fork(void)
3 {
4     ...
5     np->trace_mask = p->trace_mask;
6     ...
7 }
```

(5) 修改 syscall()打印跟踪信息

- 在 kernel/syscall.c 中添加系统调用名称数组

```
1 static char *syscall_names[] = {
2     [SYS_fork]    "fork",
3     [SYS_exit]    "exit",
4     [SYS_wait]    "wait",
5     [SYS_pipe]    "pipe",
6     [SYS_read]    "read",
7     [SYS_kill]    "kill",
8     [SYS_exec]    "exec",
9     [SYS_fstat]   "fstat",
10    [SYS_chdir]    "chdir",
11    [SYS_dup]      "dup",
12    [SYS_getpid]   "getpid",
13    [SYS_sbrk]     "sbrk",
14    [SYS_sleep]    "sleep",
15    [SYS_uptime]   "uptime",
16    [SYS_open]     "open",
17    [SYS_write]    "write",
18    [SYS_mknod]    "mknod",
19    [SYS_unlink]   "unlink",
20    [SYS_link]     "link",
21    [SYS_mkdir]    "mkdir",
22    [SYS_close]    "close",
23    [SYS_trace]    "trace",
24 };
```

- 修改 syscall()函数

```
1 void
2 syscall(void)
3 {
4     int num;
5     struct proc *p = myproc();
6
7     num = p->trapframe->a7;
8     if(num > 0 && num < NELEM(syscalls) && syscalls[num]) {
9         p->trapframe->a0 = syscalls[num]();
10
11         // 新增: 检查跟踪掩码并打印信息
12         if(p->trace_mask & (1 << num)) {
13             if(num < NELEM(syscall_names) && syscall_names[num]) {
14                 printf("%d: syscall %s -> %d\n",
15                     p->pid, syscall_names[num], p->trapframe->a0);
16             }
17         }
18     } else {
19         printf("%d %s: unknown sys call %d\n",
20             p->pid, p->name, num);
21         p->trapframe->a0 = -1;
22     }
23 }
```

(6) 编译运行 xv6, 执行以下测试:

- \$ trace 32 grep hello README

```
$ trace 32 grep hello README
3: syscall read -> 1023
3: syscall read -> 971
3: syscall read -> 298
3: syscall read -> 0
```

- \$ trace 2147483647 grep hello README

```
$ trace 2147483647 grep hello README
4: syscall trace -> 0
4: syscall exec -> 3
4: syscall open -> 3
4: syscall read -> 1023
4: syscall read -> 971
4: syscall read -> 298
4: syscall read -> 0
4: syscall close -> 0
```

- \$ grep hello README

```
$ grep hello README
```

- \$ trace 2 usertests forkforkfork

```
$ trace 2 usertests forkforkfork
usertests starting
6: syscall fork -> 7
```

```
OK
6: syscall fork -> 69
ALL TESTS PASSED
```

- 查看得分:

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ ./grade-lab-syscall trace
make: 'kernel/kernel' is up to date.
== Test trace 32 grep == trace 32 grep: OK (0.9s)
== Test trace close grep == trace close grep: OK (0.9s)
== Test trace exec + open grep == trace exec + open grep: OK (1.1s)
== Test trace all grep == trace all grep: OK (1.1s)
== Test trace nothing == trace nothing: OK (0.7s)
== Test trace children == trace children: OK (13.2s)
```

3. 实验中遇到的问题和解决方法

首先是对 xv6 系统调用添加流程的理解，特别是 `user/usys.pl` 脚本的作用以及如何通过它生成用户态存根。通过查看 `user/user.h` 和 `user/usys.pl` 中现有系统调用的模式，我明白了需要在这两个文件以及 `kernel/syscall.h` 中同步添加新的系统调用定义。其次是 `trace_mask` 的存储位置。最初考虑将其作为全局变量，但这会影响所有进程，不符合题目要求。最终决定在 `struct proc` 中为每个进程添加一个独立的 `trace_mask`，这样可以通过父进程向子进程复制该值，实现了进程隔离和继承。

4. 实验心得体会

System call tracing 实验让我对 xv6 内核的系统调用机制有了更深入的认识。我不仅学会了如何向内核添加一个新的系统调用，还理解了系统调用从用户态到内核态的完整路径，包括用户态存根的生成、内核中的参数获取和实际执行，以及返回值的处理。通过在 `proc` 结构体中添加 `trace_mask` 并使其在 `fork` 时继承，我更好地理解了进程上下文和状态在进程创建时的复制和传递。

[Attack xv6 (moderate)]

1. 实验目的

本实验的目的是利用 xv6 内核中一个已知的安全漏洞，来突破进程间的内存隔离。这个漏洞源于在编译时有意移除的几行代码，这些代码本应在分配或释放内存页时将其内容清零。因此，新分配的内存页可能会残留之前某个进程使用过的数据。我们的目标是利用漏洞，读取另一个进程 `secret` 在其内存中写入的八字节秘密数据，并将该数据打印到标准错误输出，从而证明进程间的隔离被成功打破。

2. 实验步骤

(1) 内存未清理的漏洞：

- 在 `kernel/vm.c` 中，新分配的页面未被清理。（`memset(mem,0,sz)` 被注释掉）。
- 在 `kernel/kalloc.c` 中，释放的页面未被填充垃圾数据（两处 `memset` 被注释掉）。
- 结果：内存块在释放后再次分配时，仍保留之前的数据

(2) secret.c 的行为:

- 将 8 字节随机秘密写入内存地址 `PGROUNDDOWN(p)+32` (页起始地址+32 字节处)

- secret 进程退出后, 其内存被释放但未清零

(3) 攻击代码实现:

- 内存复用机制: 当 secret 进程释放内存后, attack 进程若能申请到同一块内存, 即可读取残留的秘密数据。

- 精确控制内存分配: 让 attack 进程申请与 secret 进程相同大小的内存块; 利用调整内存分配位置, 确保 attack 进程的内存起始地址与 secret 进程一致。

- 数据定位: secret 将数据写入页起始地址 +32 字节处, 因此 attack 需从相同偏移量读取数据。

```
1 int main(int argc, char *argv[])
2 {
3     // your code here. you should write the secret to fd 2 using write
4     // (e.g., write(2, secret, 8))
5     char *end = sbrk(PGSIZE * 17) + 16 * PGSIZE;
6     write(2, end + 32, 8);
7     exit(1);
8 }
```

(4) 测试验证:

- 运行 attacktest

```
init: starting sh
$ attacktest
OK: secret is df.cab.
$ attacktest
OK: secret is eaaaad.
```

- 修改 secret.c 验证：将 secret.c 中的 32 改为 0，攻击将失败，因为数据位置改变。原因在于 attack 仍从偏移量 32 处读取，而秘密数据实际存储在页起始位置。

3. 实验中遇到的问题和解决方法

我遇到的问题是，必须确切地知道秘密数据在页面中的位置。通过分析 user/secret.c 的源代码，我发现秘密数据被写入到 buf，而 buf 的地址是 $p + 32$ ，其中 p 是 sbrk 分配的页面起始地址。这个偏移量是成功的关键。

4. 实验心得体会

Attack xv6 实验是一个非常富有启发性的任务，它让我从一个全新的角度来审视操作系统。以往的实验都是在学习如何使用 xv6 提供的安全和隔离机制，而这个实验则让我亲身体验了当这些机制存在漏洞时，可能带来的严重后果。我深刻认识到，即使是像 memset 这样看似微不足道的操作，在内核编程中也至关重要。一个微小的代码缺陷就可能成为攻击者突破安全边界的入口。

Lab2 得分：

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ ./grade-lab-syscall
make: 'kernel/kernel' is up to date.
== Test answers-syscall.txt ==
answers-syscall.txt: OK
== Test trace 32 grep == trace 32 grep: OK (1.3s)
== Test trace close grep == trace close grep: OK (0.9s)
== Test trace exec + open grep == trace exec + open grep: OK (0.9s)
== Test trace all grep == trace all grep: OK (1.1s)
== Test trace nothing == trace nothing: OK (0.8s)
== Test trace children == trace children: OK (13.1s)
== Test attack == attack: OK (0.2s)
(Old xv6.out.attack failure log removed)
== Test time ==
time: OK
Score: 50/50
```

Lab3: Page tables

本实验将探索页表并修改它们以实现常见的操作系统功能。

切换至 pgtbl 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git fetch
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout pgtbl
branch 'pgtbl' set up to track 'origin/pgtbl'.
Switched to a new branch 'pgtbl'
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img .gdbinit __pycache__ xv6.out* \
ph barrier
```

[Inspect a user-process page table (easy)]

1. 实验目的

本实验的目的是通过运行 `pgtbltest` 用户程序，检查并理解 `xv6` 中一个用户进程的页表结构。我们将分析 `print_pgtbl` 函数输出的每个页表项（PTE），解释其包含的逻辑信息，特别是物理地址和权限位。这个实验旨在帮助我们深入理解 RISC-V 架构下的分页机制，以及虚拟地址如何通过页表映射到物理地址。

2. 实验步骤

(1) 运行 `make qemu` 并运行用户程序 `pgtbltest`。 `print_pgtbl` 函数使用我们为这个实验添加到 `xv6` 中的 `pgpte` 系统调用，打印出 `pgtbltest` 进程前 10 页和最后 10 页的页表项。

```
$ pgtbltest
print_pgtbl starting
va 0x0 pte 0x21FC885B pa 0x87F22000 perm 0x5B
va 0x1000 pte 0x21FC7C17 pa 0x87F1F000 perm 0x17
va 0x2000 pte 0x21FC7807 pa 0x87F1E000 perm 0x7
va 0x3000 pte 0x21FC74D7 pa 0x87F1D000 perm 0xD7
va 0x4000 pte 0x0 pa 0x0 perm 0x0
va 0x5000 pte 0x0 pa 0x0 perm 0x0
va 0x6000 pte 0x0 pa 0x0 perm 0x0
va 0x7000 pte 0x0 pa 0x0 perm 0x0
va 0x8000 pte 0x0 pa 0x0 perm 0x0
va 0x9000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFF6000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFF7000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFF8000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFF9000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFFA000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFFB000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFFC000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFFD000 pte 0x0 pa 0x0 perm 0x0
va 0xFFFFE000 pte 0x21FD08C7 pa 0x87F42000 perm 0xC7
va 0xFFFFF000 pte 0x2000184B pa 0x80006000 perm 0x4B
print_pgtbl: OK
ugetpid_test starting
usertrap(): unexpected scause 0xd pid=4
             sepc=0x53e stval=0x3fffffd000
```

(2) PTE 结构与权限位

- RISC-V 页表项 (PTE) 格式:

- 高 44 位: 物理页号 (PPN), 指向物理内存页的起始地址。
- 低 10 位: 标志位, 包括:
 - V (Valid): 有效位 (PTE_V, 第 0 位)
 - R (Read): 可读 (PTE_R, 第 1 位)
 - W (Write): 可写 (PTE_W, 第 2 位)
 - X (Execute): 可执行 (PTE_X, 第 3 位)
 - U (User): 用户模式可访问 (PTE_U, 第 4 位)
 - 其他标志位 (如 D、A 等, 用于页替换和缓存控制)。

- 权限位解析示例:

- perm 0x5B → 二进制 0b01011011 → 标志位 V=1, R=1,

W=0, X=1, U=1（用户可读可执行）。

- perm 0x17 → 二进制 0b00010111 → 标志位 V=1, R=1, W=1, X=0, U=1（用户可读写）。

(3) 示例条目分析

- 条目 1: va 0 pte 0x21FCF45B pa 0x87F3D000 perm 0x5B
 - 虚拟地址（VA）：0x0（用户程序的起始地址）。
 - PTE 值：0x21FCF45B。
 - 物理地址（PA）：0x87F3D000（通过 PPN << 12 计算）。
 - 权限：0x5B（V=1, R=1, W=0, X=1, U=1），表示用户模式下可读可执行（通常为代码段）。
- 条目 2: va 0xFFFFD000 pte 0x0 pa 0x0 perm 0x0
 - 虚拟地址：0xFFFFD000（接近用户地址空间顶部）。
 - PTE 值：0x0 → 无效页表项（V=0）。
 - 物理地址：0x0（无效）。
 - 权限：0x0 → 无权限，访问此地址会触发页错误。

(4) 页表布局与内存映射

- 低地址区域（如 VA=0）：通常映射代码段（.text）和只读数据（.rodata），权限为 R+X。
- 中间区域：可能包含数据段（.data）、堆（heap），权限为 R+W。
- 高地址区域：栈（stack）通常位于用户地址空间顶部，权限为 R+W，且随栈增长动态映射。

3. 实验中遇到的问题和解决方法

在分析 PTE 时,我遇到的主要问题是如何将 PTE 的十六进制值正确地分解为物理地址和权限位。最初,我对 PTE 的 64 位结构不熟悉,不知道物理地址和权限位分别位于哪个位置。我的解决方法是查阅 xv6 的官方书籍以及 RISC-V 的 Sv39 分页规范。我发现物理地址是 PTE 的 10 到 44 位,而权限位是最低 10 位。通过将 PTE 值转换为二进制,我能够精确地提取出物理地址和权限位。另一个问题是对权限位含义的理解。我通过对照 xv6 源代码中对 PTE_V、PTE_R、PTE_W、PTE_X 和 PTE_U 等宏的定义,以及 RISC-V 规范,我搞清楚了每个权限位的具体功能。

4. 实验心得体会

Inspect a user-process page table 实验让我对 xv6 的虚拟内存管理有了非常直观和具体的理解。我不再仅仅停留在抽象的理论层面,而是通过实际的页表项输出来亲手分析虚拟地址到物理地址的映射过程。这个实验让我深刻体会到,一个看似简单的 PTE 值背后,包含了大量重要的信息,例如页面的物理位置以及访问权限。理解权限位(如可读、可写、可执行和用户模式访问)对于理解操作系统如何保护不同进程的内存空间至关重要。我意识到,正是通过页表,xv6 实现了对进程的隔离,防止一个进程非法访问另一个进程的内存或内核内存。这个实验是理解 xv6 内存管理机制的基石,为后续更复杂的内存相关实验打下了坚实的基础。

[Speed up system calls (easy)]

1. 实验目的

本实验的目的是通过在 xv6 中实现一个用户态和内核态共享的只读页面，来优化 `getpid()` 系统调用的性能。我们将为每个新创建的进程在 `USYSCALL` 这个特定的虚拟地址上映射一个只读页面。在这个页面的起始位置，我们将存储一个 `struct usyscall` 结构体，并用当前进程的 `PID` 对其进行初始化。通过这种方式，用户态程序可以直接从这个共享页面读取 `PID`，而无需陷入内核，从而减少了系统调用的开销。

2. 实验步骤

(1) 在 `kernel/proc.h` 的 `proc` 结构体中添加指针来保存这个共享页面的地址。

```
struct usyscall *usyscallpage;
```

(2) 进程创建时映射共享页面(`kernel/proc.c`): 在 `allocproc()` 函数中分配物理页并映射到 `USYSCALL`

```
if ((p->usyscallpage = (struct usyscall *)kalloc()) == 0)
{
    freeproc(p);
    release(&p->lock);
    return 0;
}
p->usyscallpage->pid = p->pid;
```

(3) 进程释放时清理 (`kernel/proc.c`): 在 `freeproc()` 函数中释放共享页面

```
if (p->usyscallpage)
    kfree((void *)p->usyscallpage);
p->usyscallpage = 0;
```

(4) 映射共享页面到用户空间 (kernel/proc.c)：在 kernel/proc.c 的 `proc_pagetable(struct proc *p)` 中将这个映射 (PTE) 写入 `pagetable` 中。

```
if (mappages(pagetable, TRAMPOLINE, PGSIZE,
            (uint64)trampoline, PTE_R | PTE_X) < 0)
{
    uvmfree(pagetable, 0);
    return 0;
}
```

(5) 取消 PTE 映射：在 kernel/proc.c 的 `proc_freepagetable` 函数中添加：

```
uvmunmap(pagetable, USYSCALL, 1, 0);
```

(6) 查看得分：

```
(base) xiangmaster@localhost: /xv6-labs-2024$ ./grade-lab-pgtbl ugetpid
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:22: SyntaxWarning: invalid escape sequence '\.
'.\.\.0x0000000000000000',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:23: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.0x0000000000000000',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:24: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.0x0000000000000000',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:25: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.\.0x0000000000000100',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:26: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.\.0x0000000000000200',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:27: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.\.0x0000000000000300',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:28: SyntaxWarning: invalid escape sequence '\.
'.\.\.(0xffffffffc0000000|0x0000003fc0000000)',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:29: SyntaxWarning: invalid escape sequence '\.
'.\.\.(0xffffffffffe00000|0x0000003fffe00000)',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:30: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.(0xffffffffffd000|0x0000003ffffd000)',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:31: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.(0xffffffffffe000|0x0000003ffffe000)',
/home/xiangmaster/xv6-labs-2024/./grade-lab-pgtbl:32: SyntaxWarning: invalid escape sequence '\.
'.\.\.\.\.(0xfffffffffff000|0x0000003fffff000)',
make: 'kernel/kernel' is up to date.
== Test pgtbltest == (1.6s)
== Test pgtbltest: ugetpid ==
pgtbltest: ugetpid: OK
```

3. 实验中遇到的问题和解决方法

我遇到的一个关键问题是，当我试图让用户态进程访问 `USYSCALL` 虚拟地址时，总是触发非法访问错误。经过排查，我意识到问题出在页表的权限设置上。在 `proc_pagetable()` 中调用

`mmappages()` 时,我没有正确地设置权限位。最初我可能只设置了内核权限,导致用户态进程无法访问该页面。通过查阅 RISC-V 的页表权限位定义,我明白了要允许用户态进程读取该页面,必须设置 `PTE_U`(用户态可访问)和 `PTE_R`(可读)这两个权限位。将 `mmappages` 的权限参数修改为 `PTE_U | PTE_R` 后,问题成功解决,用户态进程可以正常读取共享页面中的数据。这个问题的解决加深了我对 RISC-V 分页机制和权限管理的理解。

4. 实验心得体会

`Speed up system calls` 实验让我对 `xv6` 的虚拟内存管理和进程上下文有了更深入的理解。通过为每个进程专门创建一个共享只读页面,我体会到操作系统可以巧妙地利用内存映射机制来优化某些系统调用。这种将内核数据暴露给用户态的方式,虽然减少了系统调用开销,但也带来了安全性的考量,因此只读权限的设置至关重要。这个实验也让我更加熟悉了 `xv6` 进程生命周期中的关键函数,如 `allocproc`、`fork` 和 `proc_pagetable`,以及内存分配和释放机制。我认识到,一个完整的优化方案需要考虑进程的创建、销毁、以及状态变化等所有生命周期阶段。这个实验为我理解更复杂的内存管理技术和性能优化方法打下了坚实的基础。

[Print a page table (easy)]

1. 实验目的

本实验我们将实现 `vmprint()` 函数，该函数会遍历一个给定的页表，并以缩进格式打印出每个有效的页表项（PTE），包括其对应的虚拟地址、页表项的原始值和解析出的物理地址。通过这个实验，我们将加深对 RISC-V Sv39 分页机制的理解，特别是多级页表的结构和如何从页表项中提取关键信息。

2. 实验步骤

实验源代码：（在 `kernel/vm.c` 中修改 `vmprint()` 函数）

```
1  #ifdef LAB_PGTBL
2  void PRINT(pagetable_t pagetable, int level, uint64 va) {
3      uint64 sz;
4      if(level == 2) {
5          sz = 512 * 512 * PGSIZE;
6      } else if(level == 1) {
7          sz = 512 * PGSIZE;
8      } else {
9          sz = PGSIZE;
10     }
11     for(int i = 0; i < 512; i++, va += sz) {
12         pte_t pte = pagetable[i];
13         if((pte & PTE_V) == 0)
14             continue;
15         for(int j = level; j < 3; j++) {
16             printf(" ..");
17         }
18         printf("%p: pte %p pa %p\n",
19                (pagetable_t)va,
20                (pagetable_t)pte,
21                (pagetable_t)PTE2PA(pte));
22         if((pte & (PTE_R | PTE_W | PTE_X)) == 0) {
23             PRINT((pagetable_t)PTE2PA(pte), level - 1, va);
24         }
25     }
26 }
27 void
28 vmprint(pagetable_t pagetable) {
29     printf("page table %p\n", pagetable);
30     PRINT(pagetable, 2, 0);
31 }
32 #endif
```

(1) RISC-V 页表结构

- 三级页表：
 - 页全局目录（PGD, Level 2）
 - 页上级目录（PUD, Level 1）
 - 页表（PT, Level 0）
 - 每级页表有 512 个条目，每个条目 8 字节（64 位）。

(2) 虚拟地址计算：虚拟地址分为三个 9 位索引（用于查找三级页表）和 12 位页内偏移：




Figure 3.2: RISC-V address translation details.

(3) 递归逻辑打印

- 缩进处理：通过 `depth` 参数控制缩进级别。
- 虚拟地址计算：根据当前页表层级和索引计算虚拟地址。
- 递归终止条件：当 PTE 包含 `PTE_R/PTE_W/PTE_X` 标志时，视为叶节点，不再递归。

(4) 运行结果

```
print_kpgtbl starting
page table 0x0000000087f22000
..0x0000000000000000: pte 0x0000000021fc7801 pa 0x0000000087f1e000
.. ..0x0000000000000000: pte 0x0000000021fc7401 pa 0x0000000087f1d000
.. .. ..0x0000000000000000: pte 0x0000000021fc7c5b pa 0x0000000087f1f000
.. .. ..0x0000000000000100: pte 0x0000000021fc701b pa 0x0000000087f1c000
.. .. ..0x0000000000000200: pte 0x0000000021fc6cd7 pa 0x0000000087f1b000
.. .. ..0x0000000000000300: pte 0x0000000021fc6807 pa 0x0000000087f1a000
.. .. ..0x0000000000000400: pte 0x0000000021fc64d7 pa 0x0000000087f19000
..0x00000003fc000000: pte 0x0000000021fc8c01 pa 0x0000000087f23000
.. ..0x00000003fffe0000: pte 0x0000000021fc8001 pa 0x0000000087f20000
.. .. ..0x00000003fffffd00: pte 0x0000000021fd4013 pa 0x0000000087f50000
.. .. ..0x00000003fffffe00: pte 0x0000000021fd48c7 pa 0x0000000087f52000
.. .. ..0x00000003ffffff00: pte 0x000000002000184b pa 0x0000000080006000
print_kpgtbl: OK
```

3. 实验中遇到的问题和解决方法

实现 `vmprint()` 函数时，我遇到的主要问题是递归逻辑和地址计算。最初，我很难正确地根据当前的层级和索引来计算虚拟地址。我的解决方法是，首先理解页表的工作原理，即每层页表项的索引都对应虚拟地址的一部分。我通过在递归调用时，将上一层的虚拟地址加上当前层的偏移量（索引乘以页面大小），来逐步构建完整的虚拟地址。另一个问题是如何正确判断一个页表项是否是叶子节点。我通过检查 `pte` 的 `PTE_R`、`PTE_W` 或 `PTE_X` 位，来判断它是否指向实际的物理页面，而不是下一级页表。这个判断条件与 `freewalk` 函数中的逻辑类似，给了我很大的启发。

4. 实验心得体会

Print a page table 实验让我对 RISC-V 的多级页表机制有了直观的认识。通过亲手编写一个递归函数来遍历页表，我不再仅仅是理论上理解，而是能够实际看到虚拟地址是如何层层映射到物理地址的。我深刻体会到，每个页表项都是虚拟地址转换链条上的关键一环，它不仅包含了物理地址，还通过权限位实现了对内存的精细控制。这个实验也锻炼了我的递归编程能力，以及对底层硬件宏（如 `PTE_V`、`PTE_PA`）的运用。总的来说，这个实验是一个很好的工具，它能够更好地理解 xv6 内存管理的核心，也为我今后在调试内存相关问题时提供了宝贵的经验。

[Use superpages (moderate)/(hard)]

1. 实验目的

本实验的目的是修改 xv6 内核，以支持 RISC-V 架构的超大页（superpages），特别是两兆字节（megapages）。当用户程序通过 `sbrk()` 申请的内存大小为两兆字节或以上，并且该内存区域满足两兆字节对齐时，内核应使用一个超大页来映射该区域，而不是数百个普通四千零九十六字节的页。通过使用超大页，我们可以减少页表占用的物理内存，并提高 TLB 缓存命中率，从而提升程序性能。这个实验旨在帮助我们理解多级分页系统中的不同页大小机制，以及如何修改内核来支持新的内存管理策略。

2. 实验步骤

(1) 修改物理内存管理（`kernel/kalloc.c`）：预留 2MB 对齐的物理

内存区域

```
1 #define SUPERPAGESIZE (2*1024*1024)
2 static char superpages[4 * SUPERPAGESIZE] __attribute__((aligned(SUPERPAGESIZE)));
3 static int superpage_inuse[4] = {0};
4 void*
5 superalloc(void)
6 {
7     for (int i = 0; i < 4; i++) {
8         if (superpage_inuse[i] == 0) {
9             superpage_inuse[i] = 1;
10            return &superpages[i * SUPERPAGESIZE];
11        }
12    }
13    return 0; // 分配失败
14 }
15 void
16 superfree(void* pa)
17 {
18     if (pa < superpages || pa >= superpages + 4 * SUPERPAGESIZE)
19         return;
20     int i = (pa - superpages) / SUPERPAGESIZE;
21     if (i >= 0 && i < 4) {
22         superpage_inuse[i] = 0;
23     }
24 }
```

(2) 修改内存扩展逻辑 (kernel/sysproc.c 的 sys_sbrk) : sys_sbrk 调用 growproc 扩展进程内存, 需在 growproc 中添加超级页支持:

(3) 修改页表映射函数 (kernel/vm.c 的 mappages) : 支持超级页的一级页表映射 (RISC-V 一级页表项直接指向 2MB 物理页) :

(4) 修改页表复制与释放 (kernel/vm.c 的 uvmcopy 和 uvmunmap)

- uvmcopy 支持超级页复制
- uvmunmap 支持超级页释放

3. 实验中遇到的问题和解决方法

在实现超大页功能的过程中, 我遇到了几个关键挑战。首先是页表映射层级错误, 我最初误将超级页映射到二级页表, 但通过查阅资

料并修改 `mappages` 函数, 确保对 2MB 大小的映射直接操作一级页表, 从而解决了 RISC-V 硬件无法识别的问题。其次, 在 `superfree` 函数中, 由于指针和整数类型不匹配, 代码 `(char*)pa < SUPERBASE` 报错, 我通过将 `SUPERBASE` 也强制类型转换为指针, 或者将 `pa` 统一转换为 `uint64` 整数, 消除了类型不匹配的错误。此外, 在处理 `fork` 时, 我发现 `uvmcopy` 函数未处理超级页, 导致子进程无法继承内存, 我通过在 `uvmcopy` 中增加逻辑来检测超级页 PTE, 并调用 `superalloc` 分配新页并复制内容来解决。最后, 我还解决了内存泄漏问题, 在 `uvmunmap` 中增加了对超级页的检测, 并在进程退出时调用 `superfree` 来释放相应内存。

4. 实验心得体会

Use superpages 实验让我对 RISC-V 架构下的虚拟内存管理有了更深层次的理解。我不再局限于四千零九十六字节的普通页, 而是能够从多页大小的视角来思考内存管理。我深刻体会到, 使用超大页不仅可以减少页表占用的内存, 还能提高性能, 这在现代操作系统中是一个重要的优化手段。通过修改 `kalloc.c`、`sys_sbrk()` 和 `vm.c` 等多个内核文件, 我将整个 `xv6` 系统的内存管理流程串联了起来, 从物理内存的分配到虚拟地址的映射, 再到进程的生命周期管理。这个实验让我意识到, 操作系统中的每一个设计决策都可能对性能和资源利用的权衡, 而超大页正是这种权衡的体现。这个实验为我未来探索更复杂的操作系统内存管理技术 (如页合并和动态页大小调整) 打下了坚实的基础。

Lab3 得分:

```
== Test pgtbltest == (2.9s)
== Test   pgtbltest: ugetpid ==
   pgtbltest: ugetpid: OK
== Test   pgtbltest: print_kpgtbl ==
   pgtbltest: print_kpgtbl: OK
== Test   pgtbltest: superpg ==
   pgtbltest: superpg: OK
== Test answers-pgtbl.txt ==
answers-pgtbl.txt: OK
== Test usertests == (11.1s)
== Test   usertests: all tests ==
   usertests: all tests: OK
== Test time ==
time: OK
Score: 51/51
```

Lab4: Traps

本实验探讨了系统调用如何通过中断实现。首先进行一个关于堆栈的预热练习，然后将实现一个用户级中断处理的示例。

切换至 traps 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git fetch
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout traps
branch 'traps' set up to track 'origin/traps'.
Switched to a new branch 'traps'
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img .gdbinit __pycache__ xv6.out* \
ph barrier
```

[RISC-V assembly (easy)]

1. 实验目的

本实验旨在通过分析 xv6 中的 RISC-V 汇编代码，加深对函数调用约定、寄存器使用、指令集以及内存布局的理解。通过检查 user/call.asm 文件的内容，我们将回答一系列关于函数调用、参数传递、寄存器状态和程序输出的问题。这个实验是理解 xv6 底层工作原理，特别是系统调用和异常处理机制的基础。

2. 实验步骤

- 首先使用 make fs.img 指令编译文件 user/call.c，生成可读的汇编程序文件 user/call.asm

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ make fs.img
make: 'fs.img' is up to date.
```

- 在 call.asm 中可找到函数 g、f 和 main 的代码：



```
int g(int x) {
    0: 1141          addi    sp,sp,-16
    2: e422          sd      s0,8(sp)
    4: 0800          addi    s0,sp,16
    return x+3;
}
    6: 250d          addiw   a0,a0,3
    8: 6422          ld       s0,8(sp)
    a: 0141          addi    sp,sp,16
    c: 8082          ret
```

```
int f(int x) {
    e: 1141          addi    sp,sp,-16
   10: e422          sd      s0,8(sp)
   12: 0800          addi    s0,sp,16
    return g(x);
}
   14: 250d          addiw   a0,a0,3
   16: 6422          ld       s0,8(sp)
   18: 0141          addi    sp,sp,16
   1a: 8082          ret
```

```
void main(void) {
  1c: 1101          addi    sp,sp,-32
  1e: ec06          sd      ra,24(sp)
  20: e822          sd      s0,16(sp)
  22: 1000          addi    s0,sp,32
  printf("%d %d\n", f(8)+1, 13);
  24: 4635          li       a2,13
  26: 45b1          li       a1,12
  28: 00001517      auipc   a0,0x1
  2c: 87850513      addi    a0,a0,-1928 # 8a0 <malloc+0xfe>
  30: 6be000ef      jal     6ee <printf>
  unsigned int i = 0x00646c72;
  34: 006477b7      lui     a5,0x647
  38: c7278793      addi    a5,a5,-910 # 646c72 <base+0x645c62>
  3c: fef42623      sw      a5,-20(s0)
  printf("H%x Wo%s\n", 57616, (char *)(&i));
  40: fec40613      addi    a2,s0,-20
  44: 65b9          lui     a1,0xe
  46: 11058593      addi    a1,a1,272 # e110 <base+0xd100>
  4a: 00001517      auipc   a0,0x1
  4e: 85e50513      addi    a0,a0,-1954 # 8a8 <malloc+0x106>
  52: 69c000ef      jal     6ee <printf>
  //printf("x=%d y=%d", 3);
  exit(0);
  56: 4501          li       a0,0
  58: 26e000ef      jal     2c6 <exit>
}
```

(1) 问题 1: 哪些寄存器包含传递给函数的参数? 例如, main 调用 printf 时, 哪个寄存器存储 13?

—— 在 RISC-V 调用约定中, 函数参数通过特定寄存器传递:

a1, a2, a3 等通用寄存器将保存函数的参数。通过查看 call.asm 文件中的 main 函数可知，在 main 调用 printf 时，由寄存器 a2 保存 13。

```
li    a2,13
```

(2) 问题 2：函数 f 在 main 的汇编代码中的调用位置在哪里？调用 g 的位置在哪里？（提示：编译器可能会内联函数。）

—— 查看 call.asm 文件中的 f 和 g 函数可知，函数 f 调用函数 g；函数 g 使传入的参数加 3 后返回。

```
int f(int x) {
    e: 1141          addi    sp,sp,-16
    10: e422          sd      s0,8(sp)
    12: 0800          addi    s0,sp,16
    return g(x);
}
    14: 250d          addiw   a0,a0,3
    16: 6422          ld       s0,8(sp)
    18: 0141          addi    sp,sp,16
    1a: 8082          ret
```

(3) 问题 3：函数 printf 位于哪个地址？

—— 查阅得到其地址在 0x6ee。

```
void
printf(const char *fmt, ...)
{
    6ee: 711d          addi    sp,sp,-96
    6f0: ec06          sd      ra,24(sp)
    6f2: e822          sd      s0,16(sp)
    6f4: 1000          addi    s0,sp,32
```

(4) 问题 4：在 main 中的 jalr 到 printf 之间，寄存器 ra 中的值是什么？

—— ra 的值将设置为 0x34

(5) 问题 5: 运行以下代码。

```
unsigned int i = 0x00646c72;  
  
printf("H%x Wo%s", 57616, (char *) &i);
```

输出是什么? 这里有一个 ASCII 表, 将字节映射到字符。输出取决于 RISC-V 是小端模式的事实。如果 RISC-V 是大端模式, 你需要将 `i` 设置为什么值才能得到相同的输出? 你需要将 57616 更改为不同的值吗?

—— 打印出了 He110 World。

57616 转换为十六进制是 0xe110 (因为 $0xe110 = 57616$)。

`i` 是 4 字节无符号整数, 值为 0x00646c72。在小端 (little-endian) 系统 (如 RISC-V) 中, 内存中字节的存储顺序是反向的: 0x72、0x6c、0x64、0x00。

这些字节对应的 ASCII 字符依次为: 'r' (0x72)、'l' (0x6c)、'd' (0x64)、'\0' (0x00, 字符串结束符), 因此字符串为 "rld"。所以输出为: He110 World

大端 (big-endian) 调整: 在大端系统中, 字节按原值顺序存储。要得到相同输出, `i` 的值需设为 0x726c6400 (确保内存中字节顺序为 0x72、0x6c、0x64、0x00)。57616 是数值, 与字节顺序无关, 因此无需修改。

(6) 在以下代码中, 'y=' 之后将打印什么? (注意: 答案不是特定值。) 为什么会这样? `printf("x=%d y=%d", 3);`

—— 函数的参数是通过寄存器 `a1`, `a2` 等来传递。如果 `printf` 少

传递一个参数，那么其仍会从一个确定的寄存器中读取其想要的参数值，但是我们没有给出并存储这个确定的参数，所以函数将从此寄存器中获取到一个随机的不确定的值作为其参数。故而此例中，`y=` 后面的值我们无法确定，它是一个垃圾值。

3. 实验中遇到的问题和解决方法

分析汇编代码时，我遇到的主要问题是对 RISC-V 汇编指令和函数调用约定的不熟悉。例如，我需要查阅手册才能知道 `a0-a7` 是用来传递参数的，以及 `ra` 寄存器在 `jalr` 指令后的确切值。另一个问题是理解编译器可能会对代码进行优化，比如内联函数，这导致 `f` 和 `g` 的调用可能不是以传统的 `call` 指令形式出现。我的解决方法是仔细阅读 `call.asm` 文件，并通过对比 C 语言源代码和汇编代码，来推断出编译器是如何实现这些函数的。对于大端和小端序的问题，我通过手动模拟数据在内存中的存储方式，并对照 ASCII 表来得出结论。

4. 实验心得体会

RISC-V assembly 实验是我深入理解 xv6 的一个重要起点。通过直接分析汇编代码，我能够看到编译器是如何将 C 语言代码翻译成机器指令的，这让我对计算机的底层工作方式有了更清晰的认识。我学会了如何追踪函数调用、查看寄存器的值，并理解了函数参数是如何在寄存器和栈上传递的。这个实验也让我明白了大小端序在内存中的体现，以及为什么变参函数调用需要格外小心。总的来说，这个实验不仅巩固了我对 RISC-V 汇编的知识，也为我今后在调试 xv6 内核时，能够通过查看底层汇编代码来定位问题打下了坚实的基础。

[Backtrace (moderate)]

1. 实验目的

本实验的目的是在 xv6 内核中实现一个 `backtrace()` 函数，用于打印函数调用栈的回溯信息。通过遍历函数调用栈上的栈帧，我们能够追溯程序在发生错误或特定事件（例如系统调用）时所处的函数调用链。这将是一个非常有用的调试工具，能帮助我们理解和定位内核中的问题。我们将通过 `sys_sleep` 系统调用来测试这个功能，并使用 `addr2line` 工具将回溯地址转换为源代码的行号，以验证其正确性。

2. 实验步骤

(1) 在 `kernel/riscv.h` 中添加读取寄存器 `s0`（帧指针）的函数，用于获取当前栈帧的起始地址：

```
1 #ifndef __ASSEMBLER__
2 // get the frame pointer stored in s0
3 static inline uint64
4 r_fp()
5 {
6     uint64 x;
7     asm volatile("mv %0, s0" : "=r"(x));
8     return x;
9 }
```

(2) 在 `kernel/printf.c` 中实现回溯功能，遍历栈帧并打印返回地址：

```
1 void backtrace(void)
2 {
3     uint64 fp = r_fp();
4     uint64 page = PGROUNDDOWN(fp);
5     while (PGROUNDDOWN(fp) == page)
6     {
7         printf("%p\n", (void *)*(uint64 *) (fp - 8)); // 打印十六进制形式的帧指针
8         fp = *(uint64 *) (fp - 16); // 将 fp 看作是指针时指向的地址
9     }
10 }
11
```

(3) 在 `kernel/defs.h` 中添加 `backtrace` 函数的声明，使其可在其他文件中调用：

```
void backtrace(void);
```

(4) 修改 `kernel/sysproc.c` 的 `sys_sleep` 函数，插入 `backtrace` 调用以验证功能：

```
uint64  
sys_sleep(void)  
{  
    backtrace();  
}
```

(5) 修改 `kernel/printf.c` 的 `panic` 函数，使其在系统崩溃时自动打印回溯信息：

```
void panic(char *s)  
{  
    backtrace();  
}
```

(6) 编译运行：

```
$ bttest  
0x0000000080001e16  
0x0000000080001d38  
0x0000000080001a76  
0x0000000080001a76
```

(7) 使用 `addr2line` 解析地址：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ addr2line -e kernel/kernel  
0x0000000080001e16  
/home/xiangmaster/xv6-labs-2024/kernel/sysproc.c:58  
0x0000000080001d38  
/home/xiangmaster/xv6-labs-2024/kernel/syscall.c:145 (discriminator 1)  
0x0000000080001a76  
/home/xiangmaster/xv6-labs-2024/kernel/trap.c:79
```

3. 实验中遇到的问题和解决方法

实现 `backtrace` 函数的过程中，我遇到了几个关键问题。首先，由于 `backtrace` 函数在 `sys_sleep` 中调用时未声明，导致了编译错误，解决方法是在 `kernel/defs.h` 中添加了函数原型以确保跨文件调用的有效性。其次，栈帧遍历出现了无限循环，问题在于未能正确判断栈帧的终止条件，我通过 `PGROUNDDOWN(fp)` 宏来确保只遍历当前栈页内的栈帧，一旦 `fp` 超出这个范围即停止。此外，我还遇到了返回地址解析错误，这源于我错误地计算了返回地址和上一级帧指针在栈帧中的偏移，根据 RISC-V 栈帧布局，我将返回地址的偏移量修正为 -8，将上一级帧指针的偏移量修正为 -16，从而确保了地址的正确性。最后，在实现 `r_fp` 函数时，我最初遇到了内联汇编语法错误，无法正确读取 `s0` 寄存器，我通过使用正确的 RISC-V 汇编指令 `mv %0, s0` 并配合正确的约束 `"=r"`，成功解决了这个问题。

4. 实验心得体会

Backtrace 实验让我对 xv6 的运行环境有了非常深入的理解。通过亲手实现一个回溯函数，我不仅学会了如何使用内联汇编来访问特定的寄存器（如 `s0`），还掌握了如何通过栈帧指针来遍历函数调用栈。我深刻体会到，函数调用栈不仅是数据存储的地方，也是程序执行路径的“历史记录”。能够打印出这个历史记录，对于调试那些难以复现的内核错误至关重要。这个实验让我认识到，调试工具本身也是需要精心设计的，而 `backtrace` 就是其中最基本和强大的工具之一。这个实验也为我今后在 xv6 内核中遇到崩溃等问题时，提供了一个强大的定位手段。

[Alarm (hard)]

1. 实验目的

本实验的目的是在 xv6 中实现一个用户级的定时警报功能。我们将添加一个 `sigalarm(interval, handler)` 系统调用，允许用户程序指定一个时间间隔 `n`，在每经过 `n` 个时钟中断后，内核将强制调用用户提供的处理函数 `fn`。当 `fn` 执行完毕后，程序应能无缝地从被中断的地方恢复执行。此外，用户处理函数需要调用一个新的 `sigreturn` 系统调用来通知内核，以便正确恢复上下文。这个实验旨在让我们理解用户级中断处理机制、进程上下文的保存与恢复，以及系统调用与中断处理之间的协作。

2. 实验步骤

(1) 添加系统调用框架：

- 在 `kernel/syscall.h` 中添加：

```
#define SYS_sigalarm 22
#define SYS_sigreturn 23
```

- 在 `user/user.h` 中添加用户态函数原型：

```
int sigalarm(int ticks, void (*handler)());
int sigreturn(void);
```

- 在 `user/usys.pl` 中添加系统调用入口：

```
entry("sigalarm");
entry("sigreturn");
```

- 在 `kernel/syscall.c` 中添加函数指针和声明：

```
extern uint64 sys_sigalarm(void);
extern uint64 sys_sigreturn(void);

// An array mapping syscall numbers fr
// to the function that handles the sy
static uint64 (*syscalls[])(void) = {
[SYS_fork]    sys_fork,
[SYS_exit]    sys_exit,
[SYS_wait]    sys_wait,
[SYS_pipe]    sys_pipe,
[SYS_read]    sys_read,
[SYS_kill]    sys_kill,
[SYS_exec]    sys_exec,
[SYS_fstat]   sys_fstat,
[SYS_chdir]   sys_chdir,
[SYS_dup]     sys_dup,
[SYS_getpid]  sys_getpid,
[SYS_sbrk]    sys_sbrk,
[SYS_sleep]   sys_sleep,
[SYS_uptime]  sys_uptime,
[SYS_open]    sys_open,
[SYS_write]   sys_write,
[SYS_mknod]   sys_mknod,
[SYS_unlink]  sys_unlink,
[SYS_link]    sys_link,
[SYS_mkdir]   sys_mkdir,
[SYS_close]   sys_close,
[SYS_sigalarm] sys_sigalarm,
[SYS_sigreturn] sys_sigreturn,
};
```

(2) 在 kernel/proc.h 中添加闹钟相关字段:

```
1 struct proc {
2     struct spinlock lock;
3
4     // p->lock must be held when using these:
5     enum procstate state; // Process state
6     void *chan;           // If non-zero, sleeping on chan
7     int killed;           // If non-zero, have been killed
8     int xstate;           // Exit status to be returned to parent's wait
9     int pid;              // Process ID
10
11     // wait_lock must be held when using this:
12     struct proc *parent; // Parent process
13
14     // these are private to the process, so p->lock need not be held.
15     uint64 kstack;        // Virtual address of kernel stack
16     uint64 sz;            // Size of process memory (bytes)
17     pagetable_t pagetable; // User page table
18     struct trapframe *trapframe; // data page for trampoline.S
19     struct context context; // switch() here to run process
20     struct file *ofile[NOFILE]; // Open files
21     struct inode *cwd;        // Current directory
22     char name[16];           // Process name (debugging)
23     int alarm_interval;
24     void (*alarm_handler)();
25     int alarm_ticks; //remain ticks
26     int in_handler;
27     struct trapframe sig_trapframe;
28 };
```

(3) 在 kernel/proc.c 的 allocproc 中初始化新增字段:

```
memset(&p->context, 0, sizeof(p->context));
p->context.ra = (uint64)forkret;
p->context.sp = p->kstack + PGSIZE;

p->alarm_interval = 0;
p->alarm_handler = 0;
p->alarm_ticks = 0;
p->in_handler = 0;
memset(&p->sig_trapframe, 0, sizeof(p->sig_trapframe));
return p;
```

(4) 实现 sys_sigalarm 系统调用:

```
1  uint64 sys_sigalarm(void)
2  {
3      int ticks;
4      uint64 handler;
5
6      struct proc *p = myproc();
7      argint(0, &ticks);
8      argaddr(1, &handler);
9      if (ticks < 0)
10     {
11         return -1;
12     }
13     if (ticks == 0)
14     {
15         // 取消定时器
16         p->alarm_interval = 0;
17         p->alarm_handler = 0;
18         p->alarm_ticks = 0;
19     }
20     else
21     {
22         p->alarm_interval = ticks;
23         p->alarm_handler = (void (*)(void))handler;
24         p->alarm_ticks = ticks;
25     }
26     return 0;
27 }
```

(5) 实现 sys_sigreturn 系统调用:

```

1 uint64 sys_sigreturn(void)
2 {
3     struct proc *p = myproc();
4     if (!p->in_handler)
5         return -1;
6     // uint64 kernel_satp = p->trapframe->kernel_satp;
7     // uint64 kernel_sp = p->trapframe->kernel_sp;
8     // uint64 kernel_trap = p->trapframe->kernel_trap;
9     // uint64 kernel_hartid = p->trapframe->kernel_hartid;
10    memmove(p->trapframe, &p->sig_trapframe, sizeof(struct trapframe));
11    // p->trapframe->kernel_satp = kernel_satp;
12    // p->trapframe->kernel_sp = kernel_sp;
13    // p->trapframe->kernel_trap = kernel_trap;
14    // p->trapframe->kernel_hartid = kernel_hartid;
15    p->in_handler = 0;
16    //printf("\nvalue of ptrapframe a0 is %lx,    psigtrapframe a0 is %lx\n", p->trapframe->a0, p->sig_trapframe.a0);
17    return p->trapframe->a0;
18 }

```

(6) 修改陷阱处理逻辑（kernel/trap.c），在 usertrap 中添加闹钟触发逻辑：

```

// give up the CPU if this is a timer interrupt.
if (which_dev == 2)
{
    struct proc *p = myproc();
    if (p->alarm_interval > 0)
    {
        p->alarm_ticks--;
        if (p->alarm_ticks == 0 && p->in_handler == 0)
        {
            //先保存旧的trapframe再设置新的epc!
            memmove(&p->sig_trapframe, p->trapframe, sizeof(struct trapframe));
            p->in_handler = 1;
            p->alarm_ticks = p->alarm_interval;
            p->trapframe->epc = (uint64)p->alarm_handler;
            //printf("\nvalue of ptrapframe a0 is %lx,psigtrapframe a0 is %lx\n",p->t
        }
    }
    yield();
}
}

```

(7) 释放资源（kernel/proc.c），在进程退出时释放 alarm_tf 分配的内存,在 freeproc 添加：

```
static void
freeproc(struct proc *p)
{
    if(p->trapframe)
        kfree((void*)p->trapframe);
    p->trapframe = 0;
    if(p->pagetable)
        proc_freepagetable(p->pagetable, p->sz);
    p->pagetable = 0;
    p->sz = 0;
    p->pid = 0;
    p->parent = 0;
    p->name[0] = 0;
    p->chan = 0;
    p->killed = 0;
    p->xstate = 0;
    p->state = UNUSED;
    p->alarm_handler=0;
    p->alarm_interval=0;
    p->alarm_ticks=0;
    memset(&p->sig_trapframe, 0, sizeof(p->sig_trapframe));
}
```

(8) 在 Makefile 的 UPROGS 中添加 alarmtest

(9) 编译并运行测试

```
init: starting sh
$ alarmtest
test0 start
.....alarm!
test0 passed
test1 start
.....alarm!
.....alarm!
.....alarm!
.....alarm!
.....alarm!
.....alarm!
.....alarm!
.....alarm!
.....alarm!
test1 passed
test2 start
.....alarm!
test2 passed
test3 start
test3 passed
```

运行 `usertests -q` 来确保你的修改没有影响到内核的其他部分。

- `test0`: 验证闹钟能触发处理函数 `periodic`。
- `test1`: 验证处理函数返回后进程能继续执行，且闹钟按间隔触发。
- `test2`: 验证处理函数未返回时不会重入。
- `test3`: 验证 `sigalarm(0, 0)` 能停止闹钟。

```
usertrap(): unexpect
            sepc=0x
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
$
```

3. 实验中遇到的问题和解决方法

在实现 `sigalarm` 功能时，我主要解决了以下几个问题。首先是进程无法从处理函数返回，我通过在 `usertrap` 中保存完整的 `trapframe` 并在 `sigreturn` 中恢复它来确保 `sepc` 的正确性。其次是处理函数的重入问题，我添加了一个 `alarm_active` 标记，在处理函数执行期间阻止新的警报触发。此外，我还解决了寄存器状态不一致的问题，通过恢复整个 `trapframe` 确保了所有寄存器与中断前一致。最后，我确保了闹钟计数的准确性，通过在每次时钟中断时正确递减 `alarm_ticks` 来实现。

4. 实验心得体会

Alarm 实验是我对 `xv6` 操作系统内核理解的一个巨大飞跃。我不

仅学会了如何添加和实现新的系统调用，更重要的是，我深入理解了中断处理、上下文切换以及用户-内核交互的底层机制。通过实现用户级的定时器中断，我掌握了如何保存和恢复一个进程的完整上下文，这对于理解现代操作系统中的抢占式调度、信号处理等概念至关重要。我体会到，`trapframe` 不仅仅是一个结构体，它代表着一个进程在特定时刻的“快照”，保存和恢复这个快照是实现无缝上下文切换的关键。这个实验也让我认识到了设计用户-内核接口的重要性，`sigreturn` 系统调用的引入就是为了在用户态和内核态之间建立一个清晰的协议，确保状态能够正确恢复。总的来说，这个实验极大地提升了我对操作系统核心原理的实践能力。

Lab4 得分:

```
(base) xiangmaster@localhost: /xv6-labs-2024$ ./grade-lab-traps
make: 'kernel/kernel' is up to date.
== Test answers-traps.txt ==
answers-traps.txt: OK
== Test backtrace test == backtrace test: OK (1.2s)
== Test running alarmtest == (3.6s)
== Test alarmtest: test0 ==
alarmtest: test0: OK
== Test alarmtest: test1 ==
alarmtest: test1: OK
== Test alarmtest: test2 ==
alarmtest: test2: OK
== Test alarmtest: test3 ==
alarmtest: test3: OK
== Test usertests == usertests: OK (174.2s)
== Test time ==
time: OK
Score: 95/95
```

Lab5: Copy-on-Write Fork for xv6

虚拟内存提供了一层间接性：内核可以通过将 PTE 标记为无效或只读来拦截内存引用，从而引发页错误，并且可以通过修改 PTE 来改变地址的含义。在计算机系统中，有一个说法是任何系统问题都可以通过一层间接性来解决。本实验将实现写时复制（Copy-on-Write, COW）机制的 fork 系统调用，优化 xv6 中进程创建的性能。

切换至 cow 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git fetch
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout cow
Switched to branch 'cow'
Your branch is up to date with 'origin/cow'.
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img .gdbinit __pycache__ xv6.out* \
ph barrier
```

问题：

xv6 中的 fork() 系统调用会将父进程的所有用户空间内存复制到子进程中。如果父进程很大，拷贝可能需要很长时间。更糟糕的是，这些工作往往会被浪费掉；例如，子进程中的 fork() 之后的 exec() 会导致子进程丢弃复制的内存，而且很可能不会使用其中的大部分内存。另一方面，如果父进程和子进程都使用一个页面，并且其中一个或两个都写入了该页面，则确实需要复制。

解决方案：

写入时拷贝（COW）fork() 的目的是推迟为子代分配和拷贝物理内存页，直到实际需要时才拷贝（如果需要的话）。

COW `fork()` 只为子进程创建一个分页表，用户内存的 PTE 指向父进程的物理页面。COW `fork()` 会将父进程和子进程中的所有用户 PTE 标记为不可写。当任何一个进程试图写入这些 COW 页面时，CPU 都会强制产生一个页面故障。内核页面故障处理程序会检测到这种情况，为故障进程分配一个物理内存页面，将原始页面复制到新页面，并修改故障进程中的相关 PTE，使其指向新页面，这次的 PTE 标记为可写。当页面故障处理程序返回时，用户进程将能写入其页面副本。

COW `fork()` 在释放实现用户内存的物理页时比较麻烦。一个给定的物理页可能被多个进程的页表引用，只有当最后一个引用消失时，才能释放该页。

[Implement copy-on-write fork (hard)]

1. 实验目的

本实验的目的是在 xv6 内核中实现写时复制（Copy-on-Write, COW）的 `fork()`。在传统的 `fork()` 中，子进程会完整复制父进程的地址空间，这在物理内存不足时可能导致 `fork()` 失败。通过实现 COW `fork`，父子进程最初共享相同的物理内存页面。当任一进程试图修改共享页面时，操作系统才会为该进程分配新的物理页面并复制内容，从而推迟内存复制直到实际需要时。这个机制解决了传统 `fork` 的内存开销问题，提高了性能和资源利用率。

2. 实验步骤

(1) 在 kernel/riscv.h 中定义 PTE_COW 标志（使用 PTE 的预留位）：

```
#define PTE_COW (1L << 8) // COW bit
```

(2) 实现物理页引用计数

- 在 kernel/kalloc.c 中添加引用计数管理：

```
1 // 获取物理地址对应的引用计数数组索引
2 static int
3 pa2index(uint64 pa)
4 {
5     if (pa < (uint64)end)
6         return -1;
7     uint64 idx = (pa - (uint64)end) / PGSIZE;
8     if (idx >= MAXPAGES)
9         return -1;
10    return idx;
11 }
```

```
1 // 增加引用计数
2 void
3 inc_ref(void *pa){
4     int idx = pa2index((uint64)pa);
5     if (idx < 0)
6         return;
7
8     acquire(&kmem.lock);
9     kmem.refcount[idx]++;
10    // if(idx < 10000)
11    //     printf("inc ref at pa %ld, idx is %d, refcount is %d\n ", (uint64)pa, idx, kmem.refcount[idx]);
12    release(&kmem.lock);
13 }
```

```
1 // 获取引用计数
2 int get_ref(void *pa)
3 {
4     int idx = pa2index((uint64)pa);
5     int count;
6     if (idx < 0)
7         return -1;
8
9     acquire(&kmem.lock);
10    count = kmem.refcount[idx];
11    release(&kmem.lock);
12    return count;
13 }
```

```

1 void
2 kfree(void *pa)
3 {
4     struct run *r;
5
6     if(((uint64)pa % PGSIZE) != 0 || (char*)pa < end || (uint64)pa >= PHYSTOP)
7         panic("kfree");
8
9     int idx = pa2index((uint64)pa);
10    if (idx < 0 || kmem.refcount[idx] <= 0){
11        printf("end is %lx, pa is %lx, idx is %d, ref count is %d\n", (uint64)end, (uint64)pa, idx, kmem.refcount[idx]);
12        panic("kfree: invalid pa or refcount");
13    }
14    acquire(&kmem.lock);
15    int count = --kmem.refcount[idx];
16    // Fill with junk to catch dangling refs.
17    if(count==0)
18    {
19        memset(pa, 1, PGSIZE);
20        r = (struct run *)pa;
21        r->next = kmem.freelist;
22        kmem.freelist = r;
23    }
24    release(&kmem.lock);
25 }

```

- 在 kinit() 中初始化引用计数:

```

1 void
2 kinit()
3 {
4     initlock(&kmem.lock, "kmem");
5     freerange(end, (void*)PHYSTOP);
6 }

```

(3) 修改 fork 实现 COW 共享

- 修改 kernel/vm.c 的 uvmcopy, 实现父子进程共享物理页（而非复制）:

```

1  int
2  uvmcopy(pagetable_t old, pagetable_t new, uint64 sz)
3  {
4      pte_t *pte;
5      uint64 pa, i;
6      uint flags;
7      //char *mem;
8
9      for(i = 0; i < sz; i += PGSIZE){
10         if((pte = walk(old, i, 0)) == 0)
11             panic("uvmcopy: pte should exist");
12         if((*pte & PTE_V) == 0)
13             panic("uvmcopy: page not present");
14         pa = PTE2PA(*pte);
15         if(*pte & PTE_W){
16             *pte = *pte | PTE_COW; //如果原来是writable,将cow bit设置成1
17             *pte = *pte & (~PTE_W); //将write bit设置为0
18         }
19         flags = PTE_FLAGS(*pte);
20         // if((mem = kalloc()) == 0)
21         //     goto err;
22         // memmove(mem, (char*)pa, PGSIZE);
23         if(mappages(new, i, PGSIZE, pa, flags) != 0){
24             //kfree(mem);
25             goto err;
26         }
27         inc_ref((void *)pa);
28     }
29     return 0;
30
31 err:
32     uvmunmap(new, 0, i / PGSIZE, 0);
33     return -1;
34 }

```

(4) 处理 COW 页错误

- 在 kernel/trap.c 的 usertrap 中添加页错误处理逻辑:

```

1  else if( r_scause() == 15 ){
2      struct proc* p = myproc();
3      uint64 va = r_stval();
4      if (va >= MAXVA){
5          setkilled(p);
6          goto err;
7      }
8      pte_t *pte = walk(p->pagetable, va, 0);
9
10     if (pte == 0 || (*pte & PTE_V) == 0 || (*pte & PTE_U) == 0 )
11     {

```

```

12     setkilled(p);
13     goto err;
14 }
15 if (*pte & PTE_COW){
16     uint64 pa = PTE2PA(*pte);
17     // book p49: This book-keeping allows an important optimization: if a process incu
18     // physical page is only referred to from that process's page table, no copy is ne
19     if (get_ref((void *)pa) == 1)
20     {
21         // 清除COW位并设置写权限
22         *pte &= ~PTE_COW; // 清除COW位
23         *pte |= PTE_W;     // 设置写权限
24         sfence_vma();
25     }
26     else
27     {
28         char *mem = kalloc();
29         if (mem == 0)
30         {
31             printf("usertrap(): kalloc failed!pid=%d\n", p->pid);
32             printf("usertrap(): unexpected scause 0x%lx pid=%d\n", r_scause(), p->pid);
33             setkilled(p);
34         }
35         memmove(mem, (char *)pa, PGSIZE);
36
37         uint flags = PTE_FLAGS(*pte);
38         flags &= ~PTE_COW;
39         flags |= PTE_W;
40         *pte = PA2PTE(mem) | flags | PTE_V;
41         //dec_ref((void *)pa);
42         kfree((void *)pa);
43         sfence_vma();
44     }
45 }
46 else
47 {
48     printf("usertrap(): write to read-only page\n");
49     setkilled(p);
50 }
51 }

```

(5) 运行测试:

- cowtest 测试

```

$ cowtest
simple: ok
simple: ok
three: ok
three: ok
three: ok
file: ok
forkfork: ok
ALL COW TESTS PASSED

```

- usertests -q

```

test sbrkbugs: usert
                sepc=0x4f
usertrap(): unexpect
                sepc=0x4f
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
$

```

- `simple` 测试验证了内存不足时 COW 能成功创建进程。
- `three` 测试验证了多进程共享与复制的正确性。
- `file` 测试验证了文件映射页的 COW 处理。
- `usertests` 验证了 COW 机制对其他内核功能无干扰。

3. 实验中遇到的问题和解决方法

在实现写时复制 `fork` 的过程中，我主要遇到了以下几个问题。

(1) 引用计数管理：如何为每个物理页帧维护一个引用计数器是一个挑战。我最初尝试使用动态分配的数组，但发现这在内核中实现起来很复杂。最终的解决方案是创建一个固定大小的整数数组，其大小与 `kinit()` 预分配的物理内存页面数量相同，并以页帧的物理地址除以 `PGSIZE` 作为索引，从而高效地管理引用计数。

(2) 写时复制逻辑：在 `uvmcopy()` 和 `usertrap()` 中实现 COW 逻辑是另一个难点。我误以为只需在 `uvmcopy()` 中简单地将页表项设置为只读，但忽略了在缺页中断时如何处理。通过参考 `xv6` 书籍，我意识到 COW 的核心是推迟物理内存的分配和复制。我需要在 `uvmcopy()` 中将父子进程的地址空间进行相同的映射，但将 PTE 标记为只读。然后在 `usertrap()` 中，当发生写缺页中断时，才真正进行内存分配和复制，并更新页表项为可写。

(3) `copyout()` 处理：`copyout()` 函数在将内核数据复制到用户空间时，如果目标页面是 COW 页面，也会导致问题。我需要修改 `copyout()`，使其在遇到 COW 页面时，也能触发与缺页中断相似的逻辑，先进行页面的私有化，再进行数据复制。

4. 实验心得体会

Implement copy-on-write fork 实验让我对操作系统内存管理的核心机制有了极其深入的理解。我体会到 COW fork 的目标是推迟到子进程实际需要物理内存拷贝时再进行分配和复制。通过这次实践，我明白了操作系统如何通过巧妙地利用页表来实现进程间的内存共享和隔离。我学会了如何通过引用计数来安全地管理共享资源，如何处理缺页中断，以及如何在内核的不同部分协同工作以实现复杂的内存管理策略。这个实验不仅让我掌握了 COW fork 的技术细节，也加深了我对操作系统原理的理解，尤其是对性能和资源利用率的权衡考量。

Lab5 得分:

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ ./grade-lab-cow
make: 'kernel/kernel' is up to date.
== Test running cowtest == (27.1s)
== Test    simple ==
    simple: OK
== Test    three ==
    three: OK
== Test    file ==
    file: OK
== Test  forkfork ==
    forkfork: OK
== Test usertests == (77.9s)
== Test  usertests: copyin ==
    usertests: copyin: OK
== Test  usertests: copyout ==
    usertests: copyout: OK
== Test  usertests: all tests ==
    usertests: all tests: OK
== Test time ==
time: OK
Score: 130/130
```

Lab6: networking

我们将编写一个 xv6 网络接口卡（NIC）的设备驱动程序，然后编写一个以太网/IP/UDP 协议处理栈的接收部分。

切换至 net 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git fetch
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout net
branch 'net' set up to track 'origin/net'.
Switched to a new branch 'net'
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img .gdbinit __pycache__ xv6.out* \
ph barrier
```

E1000 网卡简介：E1000 是 Intel 一款千兆以太网控制器，实验中通过 QEMU 模拟该网卡。驱动需与网卡的寄存器交互，完成数据包的收发：

- 发送：驱动将数据包写入网卡的发送队列，触发发送。
- 接收：网卡收到数据包后存入接收队列，通过中断通知内核处理。

网络协议栈：xv6 已实现 UDP 发送逻辑，需补充接收逻辑，涉及三层协议：

- 以太网（Ethernet）：处理 MAC 地址和帧类型。
- IP：处理 IP 地址、协议类型（如 UDP）和校验和。
- UDP：处理端口号，将数据包交付给对应用户进程。

关键文件：

- kernel/e1000.c：E1000 驱动实现（收发逻辑）。

- kernel/e1000_dev.h: E1000 寄存器和标志位定义。
- kernel/net.c/net.h: IP、UDP、ARP 协议处理（需补全接收逻辑）。
- kernel/pci.c: PCI 总线扫描，初始化 E1000 设备。

[NIC (moderate)]

1. 实验目的

本实验的目的是完成 xv6 中 E1000 网卡驱动的 `e1000_transmit()` 和 `e1000_recv()` 函数。这两个函数分别负责处理以太网数据包的发送和接收。通过实现这些功能，我们将使 xv6 能够与外部网络进行通信，理解网卡驱动与硬件的交互方式，包括 DMA（直接内存访问）机制、描述符环（`transmit/receive rings`）的管理，以及如何通过内存映射控制寄存器与 E1000 网卡进行通信。

2. 实验步骤

(1) 实现数据包发送（`e1000_transmit`）：将用户数据包添加到发送队列，通知网卡发送，并在发送完成后释放缓冲区。

```
1 int e1000_transmit(char *buf, int len)
2 {
3     //
4     // Your code here.
5     //
6     // buf contains an ethernet frame; program it into
7     // the TX descriptor ring so that the e1000 sends it. Stash
8     // a pointer so that it can be freed after send completes.
9     //
10    // Acquire lock to prevent concurrent access
11    acquire(&e1000_lock);
12    // Get current transmit descriptor index
13    int tail = regs[E1000_TDT];
14    // Check if transmit ring is full by checking DD (Descriptor Done) bit
15    if (!(tx_ring[tail].status & E1000_TXD_STAT_DD))
```

```
16 {
17     release(&e1000_lock);
18     return -1; // Ring is full
19 }
20 // Free last transmitted buffer if exists
21 if (tx_bufs[tail])
22 {
23     kfree(tx_bufs[tail]);
24 }
25 // Store buffer pointer for later freeing
26 tx_bufs[tail] = buf;
27 // Setup transmit descriptor
28 tx_ring[tail].addr = (uint64)buf;
29 tx_ring[tail].length = len;
30 // Set necessary command flags:
31 // EOP - End of Packet
32 // RS - Report Status
33 tx_ring[tail].cmd = E1000_TXD_CMD_EOP | E1000_TXD_CMD_RS;
34 // Clear status
35 tx_ring[tail].status = 0;
36 // Update tail pointer
37 regs[E1000_TDT] = (tail + 1) % TX_RING_SIZE;
38 release(&e1000_lock);
39 return 0;
40 }
```

通过 `acquire(&e1000_lock)` 获取互斥锁，以确保并发安全。接着，它从 `regs[E1000_TDT]` 寄存器读取当前的发送队列尾部索引 `tail`。函数检查 `tx_ring[tail]` 描述符的 `status` 字段，如果 `E1000_TXD_STAT_DD` 位未设置，表示队列已满，则释放锁并返回 -1。如果队列可用，它会释放该描述符之前可能关联的缓冲区，然后将传入的 `buf` 缓冲区地址和长度填充到 `tx_ring[tail]` 描述符中，并设置 `E1000_TXD_CMD_EOP | E1000_TXD_CMD_RS` 命令标志。最后，更新 `regs[E1000_TDT]` 寄存器指向下一个可用位置，释放锁，并返回 0 表示成功。

(2) 实现数据包接收 (`e1000_rcv`)：从接收队列读取新数据包，交给协议栈处理，并分配新缓冲区供下次接收。

```
1 static void
2 e1000_rcv(void)
3 {
4     //
5     // Your code here.
6     //
7     // Check for packets that have arrived from the e1000
8     // Create and deliver a buf for each packet (using net_rx()).
9     //
10    // Get current receive descriptor position
11    while (1)
12    {
13        // Get next descriptor to check
14        int tail = (regs[E1000_RDT] + 1) % RX_RING_SIZE;
15        // Check if new packet is available
16        if (!(rx_ring[tail].status & E1000_RXD_STAT_DD))
17        {
18            break;
19        }
20        // If packet has no errors
21        if (rx_ring[tail].status & E1000_RXD_STAT_EOP)
22        {
23            // Get the received packet length
24            int length = rx_ring[tail].length;
25            // Deliver packet to network stack
26            net_rx(rx_bufs[tail], length);
27            // Allocate new buffer for this descriptor
28            // Then allocate a new buffer using kalloc() to replace the one just given to net_rx()
29            rx_bufs[tail] = kalloc();
30            if (!rx_bufs[tail])
31            {
32                panic("e1000_rcv: kalloc failed");
33            }
34            // Update descriptor with new buffer
35            // Clear the descriptor's status bits to zero.
36            rx_ring[tail].addr = (uint64_t)rx_bufs[tail];
37            rx_ring[tail].status = 0;
38        }
39        // Update tail register to mark this packet as processed
40        regs[E1000_RDT] = tail;
41    }
42 }
```

`e1000_rcv` 函数在一个循环中持续检查是否有新数据包到达。它通过读取 `regs[E1000_RDT]` 并加 1（取模 `RX_RING_SIZE`）来获取下一个接收描述符的索引 `tail`。如果 `rx_ring[tail]` 描述符的 `status` 字段中的 `E1000_RXD_STAT_DD` 位被设置，则表明有新数据包到达。函数随后将该数据包缓冲区递交给 `net_rx` 进行处理，并立即调用 `kalloc()` 分配一个新的缓冲区，将其地址更新到 `rx_ring[tail]` 描述符中，以供 `E1000` 接收下一个数据包。在处理完一个数据包后，函数会更新 `regs[E1000_RDT]` 寄存器，告知硬件该位置已被软件处理，

然后继续循环检查下一个数据包。

(3) 运行测试:

- 发送测试 (txone), 测试 e1000_transmit()。

```
hart 1 starting
hart 2 starting
init: starting sh
$ nettest txone
txone: sending one packet
$
(base) xiangmaster@localhost: /xv6-labs-2024$ python3 nettest.py txone
tx: listening for a UDP packet
txone: OK
(base) xiangmaster@localhost: ~/xv6-labs-2024$
```

- 在第一个终端输入: tcpdump -XXnr packets.pcap, 可看到包含 txone 的 UDP 包:

```
reading from file packets.pcap, link-type EN10MB (Ethernet)
09:20:09.530285 IP 10.0.2.15.2003 > 10.0.2.2.26099: UDP, length 5
    0x0000: 5255 0a00 0202 5254 0012 3456 0800 4500  RU...RT..4V..E.
    0x0010: 0021 0000 0000 6411 3ebc 0a00 020f 0a00  .!....d.>.....
    0x0020: 0202 07d3 65f3 000d 0000 7478 6f6e 65     ....e.....txone
```

- 接收测试 (rxone), 测试 e1000_recv()。

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ python3 nettest.py rxone
txone: sending one UDP packet
(base) xiangmaster@localhost: ~/xv6-labs-2024$
hart 2 starting
init: starting sh
$ arp_rx: received an ARP packet
ip_rx: received an IP packet
```

- 在第二个终端输入: tcpdump -XXnr packets.pcap, 可看到 ARP 请求、ARP 回复和包含 xyz 的 UDP 包:

```
reading from file packets.pcap, link-type EN10MB (Ethernet)
09:25:44.347631 ARP, Request who-has 10.0.2.15 tell 10.0.2.2, length 46
    0x0000: ffff ffff ffff 5255 0a00 0202 0806 0001  ....RU.....
    0x0010: 0800 0604 0001 5255 0a00 0202 0a00 0202  ....RU.....
    0x0020: 0000 0000 0000 0a00 020f 0000 0000 0000  ....
    0x0030: 0000 0000 0000 0000 0000 0000
09:25:44.349014 ARP, Reply 10.0.2.15 is-at 52:54:00:12:34:56, length 28
    0x0000: 5255 0a00 0202 5254 0012 3456 0806 0001  RU...RT..4V...
    0x0010: 0800 0604 0002 5254 0012 3456 0a00 020f  ....RT..4V...
    0x0020: 5255 0a00 0202 0a00 0202
    0x0030: 0000 0000 0000 0000 0000 0000  RU.....
09:25:44.349142 IP 10.0.2.2.33770 > 10.0.2.15.2000: UDP, length 3
    0x0000: 5254 0012 3456 5255 0a00 0202 0800 4500  RT..4VRU.....E.
    0x0010: 001f 0000 0000 4011 62be 0a00 0202 0a00  ....@.b.....
    0x0020: 020f 83ea 07d0 000b 6993 7879 7a00 0000  ....i.xyz...
    0x0030: 0000 0000 0000 0000 0000 0000
```

3. 实验中遇到的问题和解决方法

在实现 E1000 网卡驱动时，我主要遇到了两大问题：一是寄存器配置问题，由于对 E1000 手册和寄存器功能理解不足，导致操作错误；我通过仔细查阅 E1000 软件开发手册，并参考 `e1000_init()` 代码，才得以正确读写 `E1000_RDT` 和 `E1000_TDT` 等关键寄存器。二是并发访问问题，`nettests` 运行中出现了 `panic: acquire` 和 `panic: release` 的错误，这表明多个进程或线程同时访问共享资源时存在数据竞争。我的解决方案是引入互斥锁机制，使用 `acquire(&e1000_lock)` 和 `release(&e1000_lock)` 来保护对描述符环等共享资源的访问，从而确保了操作的同步性，避免了数据不一致和竞争条件的发生。

4. 实验心得体会

本次实验让我深入了解了设备驱动程序的编写和调试，特别是网络设备驱动。我学会了如何初始化和操作虚拟网络设备，以及如何处理数据包的发送和接收。同时，通过解决并发访问问题，我更加深入地理解了互斥锁和同步机制在多进程/多线程环境中的重要性。理解 E1000 网卡的工作原理，包括其 DMA 机制和环形描述符队列，是本次实验的难点也是核心。这个实验不仅提升了我对操作系统 I/O 子系统的理解，也为我未来在更复杂的设备驱动开发中积累了宝贵的经验。

[UDP Receive (moderate)]

1. 实验目的

本实验的目的是在 xv6 内核中实现 UDP 协议的接收功能, 包括 `sys_recv()` 和 `sys_bind()` 系统调用, 以及 `ip_rx()` 核心逻辑。通过这些实现, 我们将使 xv6 能够接收和处理 UDP 数据包, 并将其递交给等待的用户进程。这个实验将加深对网络协议栈 (特别是 UDP 和 IP) 的理解, 并实践在内核中管理数据包队列、实现进程等待-唤醒机制以及处理用户-内核空间数据传输的技巧。

2. 实验步骤

(1) 在 `kernel/net.c` 中添加数据结构管理绑定的端口和对应的数据包队列

```
1 // 定义端口绑定和数据包队列的结构
2 #define MAX_PENDING_PACKETS 16
3 #define min(a, b) ((a) < (b) ? (a) : (b))
4
5 struct pending_packet
6 {
7     char *data;        // 数据包内容
8     int len;           // 数据包长度
9     uint32 src_ip;     // 源IP地址
10    uint16 src_port;    // 源端口
11    struct pending_packet *next;
12 };
13
14 struct bound_port
15 {
16     uint16 port;        // 绑定的端口号
17     int pending_count;  // 等待处理的包数量
18     struct spinlock lock;
19     struct pending_packet *head; // 包队列头
20     struct pending_packet *tail; // 包队列尾
21 };
22
23 #define MAX_PORTS 64
```

(2) 在 `net_init()` 中初始化锁和端口结构

```
1 void
2 netinit(void)
3 {
4     initlock(&netlock, "netlock");
5     for (int i = 0; i <= MAX_PORT; i++) {
6         initlock(&ports[i].lock, "port_queue");
7         ports[i].head = ports[i].tail = 0;
8         ports[i].count = 0;
9         ports[i].bound = 0;
10    }
11 }
```

(3) 实现 `sys_bind()` 函数：绑定端口，标记端口为“正在使用”，
允许接收该端口的 UDP 包

```
1 uint64
2 sys_bind(void)
3 {
4     int port;
5     argint(0, &port);
6
7     // 检查端口有效性
8     if (port < 0 || port > MAX_PORT)
9         return -1;
10
11     acquire(&ports[port].lock);
12     // 检查是否已绑定
13     if (ports[port].bound) {
14         release(&ports[port].lock);
15         return -1;
16     }
17     ports[port].bound = 1;
18     release(&ports[port].lock);
19
20     return 0;
21 }
```

(4) 实现 `ip_rx()`：解析 IP 包，提取 UDP 数据，将符合条件的包
加入对应端口的队列



```
1 void
2 ip_rx(char *buf, int len)
3 {
4     static int seen_ip = 0;
5     if (seen_ip == 0)
6         printf("ip_rx: received an IP packet\n");
7     seen_ip = 1;
8
9     // 检查缓冲区长度是否足够
10    if (len < sizeof(struct eth) + sizeof(struct ip) + sizeof(struct udp)) {
11        kfree(buf);
12        return;
13    }
14
15    // 解析以太网头部
16    struct eth *eth = (struct eth *)buf;
17
18    // 解析IP头部
19    struct ip *ip = (struct ip *)(eth + 1);
20    int ip_header_len = (ip->ip_vhl & 0x0F) * 4; // IP头部长度 (字节)
21    if (ip_header_len < sizeof(struct ip) || ip->ip_vhl >> 4 != 4) {
22        kfree(buf);
23        return; // 不是IPv4或头部长度异常
24    }
25
26    // 只处理UDP协议
27    if (ip->ip_p != IPPROTO_UDP) {
28        kfree(buf);
29        return;
30    }
31
32    // 解析UDP头部
33    struct udp *udp = (struct udp *)((char *)ip + ip_header_len);
34    uint16_t dport = ntohs(udp->dport); // 目的端口 (网络字节序转主机字节序)
35    uint16_t sport = ntohs(udp->sport); // 源端口
36    uint16_t udp_len = ntohs(udp->ulen); // UDP总长度 (头部+数据)
37
38    // 检查UDP长度有效性
39    if (udp_len < sizeof(struct udp) ||
40        (ip_header_len + udp_len) > (len - sizeof(struct eth))) {
41        kfree(buf);
42        return;
43    }
44
45    // 计算数据长度和数据位置
46    int data_len = udp_len - sizeof(struct udp);
47    char *data = (char *)udp + sizeof(struct udp);
48
49    // 检查目的端口是否已绑定
50    if (dport < 0 || dport > MAX_PORT || !ports[dport].bound) {
51        kfree(buf);
52        return; // 端口未绑定, 丢弃数据包
53    }
54 }
```

```
55 // 分配空间存储数据包
56 struct udp_packet *p = kalloc();
57 if (!p) {
58     kfree(buf);
59     return; // 内存不足, 丢弃
60 }
61
62 // 初始化数据包
63 p->next = 0;
64 p->src_ip = ntohl(ip->ip_src); // 源IP (网络字节序转主机字节序)
65 p->src_port = sport;
66 p->len = data_len;
67 memmove(p->data, data, data_len); // 复制数据
68
69 // 将数据包加入对应端口的队列
70 struct port_queue *q = &ports[dport];
71 acquire(&q->lock);
72
73 // 若队列已满 (超过MAX_UDP_PACKETS), 丢弃新包
74 if (q->count >= MAX_UDP_PACKETS) {
75     release(&q->lock);
76     kfree(p);
77     kfree(buf);
78     return;
79 }
80
81 // 将包加入队列尾部
82 if (q->tail) {
83     q->tail->next = p;
84 } else {
85     q->head = p; // 队列为空时, 头指针指向新包
86 }
87 q->tail = p;
88 q->count++;
89
90 // 唤醒等待该端口的进程
91 wakeup(q);
92
93 release(&q->lock);
94 kfree(buf); // 释放原始缓冲区
95 }
```

(5) 实现 `sys_recv()`: 从指定端口的队列中获取最早的 UDP 包, 复制数据到用户空间, 若队列空则等待

```
1 uint64
2 sys_recv(void)
3 {
4     int dport, maxlen;
5     uint64 src_addr, sport_addr, buf_addr;
6     // 解析系统调用参数
7     argint(0, &dport);
8     argaddr(1, &src_addr);
9     argaddr(2, &sport_addr);
10    argaddr(3, &buf_addr);
11    argint(4, &maxlen);
12    // 检查端口有效性
13    if (dport < 0 || dport > MAX_PORT)
14        return -1;
15    struct port_queue *q = &ports[dport];
16    acquire(&q->lock);
17    // 检查端口是否已绑定
18    if (!q->bound) {
19        release(&q->lock);
20        return -1;
21    }
22    // 等待队列中有数据包
23    while (q->count == 0) {
24        sleep(q, &q->lock); // 释放锁并休眠，被唤醒时重新获得锁
25    }
26    // 取出队列头部的数据包
27    struct udp_packet *p = q->head;
28    q->head = p->next;
29    if (q->head == 0) {
30        q->tail = 0; // 队列为空时更新尾指针
31    }
32    q->count--;
33    release(&q->lock); // 提前释放锁，减少持有时间
34    // 复制源IP到用户空间
35    int src_ip = p->src_ip;
36    if (copyout(myproc()->pagetable, src_addr, (char *)&src_ip, sizeof(src_ip)) < 0) {
37        kfree(p);
38        return -1;
39    }
40    // 复制源端口到用户空间
41    short src_port = p->src_port;
42    if (copyout(myproc()->pagetable, sport_addr, (char *)&src_port, sizeof(src_port)) < 0) {
43        kfree(p);
44        return -1;
45    }
46    // 检查数据长度是否超过最大限制
47    // 复制数据到用户空间
48    int copy_len = p->len < maxlen ? p->len : maxlen;
49    if (copyout(myproc()->pagetable, buf_addr, p->data, copy_len) < 0) {
50        kfree(p);
51        return -1;
52    }
53    // 释放数据包
54    kfree(p);
55    return copy_len;
56 }
```

(6) 运行结果：在一个终端运行：

```
(base) xiangmaster@localhost: /xv6-labs-2024$ make qemu
qemu-system-riscv64 -machine virt -bios none -kernel kernel
egacy=false -drive file=fs.img,if=none,format=raw,id=x0 -d
user,id=net0,hostfwd=udp::26999-:2000,hostfwd=udp::31999-
p -device e1000,netdev=net0,bus=pcie.0

xv6 kernel is booting

hart 2 starting
hart 1 starting
init: starting sh
$ nettest grade
```

另一个终端运行：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ python3 nettest.py grade
txone: OK
rxone: sending one UDP packet
```

结果：

```
hart 1 starting
hart 2 starting
init: starting sh
$ nettest grade
txone: sending one packet
arp_rx: received an ARP packet
ip_rx: received an IP packet
ping0: starting
ping0: OK
ping1: starting
ping1: OK
ping2: starting
ping2: OK
ping3: starting
ping3: OK
dns: starting
DNS arecord for pdos.csail.mit.edu. is 128.52.129.126
dns: OK
free: OK
```

3. 实验中遇到的问题和解决方法

在实现 UDP Receive 功能时，我遇到了以下几个主要问题。

1. 字节序转换：IP 和 UDP 头部的多字节字段（如 IP 地址、端口号等）都是以大端序存储在网络数据包中，而 RISC-V 架构是小端序。我最初忘记了进行字节序转换，导致解析出的地址和端口号不正确。我的解决方案是严格使用 `ntohs()`（用于 2 字节）和 `ntohl()`

（用于 4 字节）函数，确保在从数据包中读取多字节字段时都进行了正确的转换。

2.阻塞和唤醒机制：`sys_recv()` 需要在没有数据包时阻塞，直到新数据包到达。我通过在 `sys_recv()` 中使用 `sleep()` 函数来让进程进入等待状态，并以端口结构体的地址作为等待通道。然后在 `ip_rx()` 中，每当有新的数据包到达时，我调用 `wakeup()` 来唤醒所有在该通道上等待的进程，从而实现了等待-唤醒机制。

4. 实验心得体会

UDP Receive 实验让我对操作系统网络协议栈的实现有了更深层次的认识。我学会了如何将底层的以太网数据包解析为上层的 UDP 数据报，并将其与用户进程的需求相匹配。这个实验让我亲身体验了在内核中维护数据结构（如 UDP 端口队列）、处理并发、实现阻塞式系统调用以及在用户和内核空间之间安全地复制数据的挑战。我深刻理解了字节序在网络编程中的重要性，以及为什么需要精心设计同步机制来保护共享资源。总的来说，这个实验将我之前在 e1000 驱动实验中获得的底层知识，与网络协议栈的高层概念连接了起来，为我未来探索更复杂的网络功能打下了坚实的基础。

Lab6 得分：



```
riscv64-unknown-elf-objdump -S kernel/kernel > kernel/kernel.asm
riscv64-unknown-elf-objdump -t kernel/kernel | sed '1,/SYMBOL TABLE/d; s/ .* / /; /^$/d' > kernel/kernel.sym
== Test running nettest == (11.7s)
== Test nettest: txone ==
nettest: txone: OK
== Test nettest: arp_rx ==
nettest: arp_rx: OK
== Test nettest: ip_rx ==
nettest: ip_rx: OK
== Test nettest: ping0 ==
nettest: ping0: OK
== Test nettest: ping1 ==
nettest: ping1: OK
== Test nettest: ping2 ==
nettest: ping2: OK
== Test nettest: ping3 ==
nettest: ping3: OK
== Test nettest: dns ==
nettest: dns: OK
== Test nettest: free ==
nettest: free: OK
== Test time ==
time: OK
Score: 171/171
(hong) xiangmaster@localhost: ~/wyf-leha-2024$
```

Lab7: Locks

本实验将获得通过重新设计代码来提高并行性的经验。在多核机器上，并行性差的一个常见症状是高锁竞争。提高并行性通常需要改变数据结构 and 锁定策略，以减少竞争。你将针对 xv6 内存分配器和块缓存进行这些操作。

切换至 lock 分支：

```
(base) xiangmaster@localhost: /xv6-labs-2024$ git checkout lock
branch 'lock' set up to track 'origin/lock'.
Switched to a new branch 'lock'
(base) xiangmaster@localhost: ~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img fs.img.bk .gdbinit __pycache__ xv6.out* \
ph barrier
```

[Memory allocator (moderate)]

1. 实验目的

本实验的目的是通过重新设计 xv6 的内核内存分配器 `kalloc`，来消除由单一空闲链表和单一锁引起的锁竞争。我们将从一个简单的、由所有 CPU 共享一个锁和空闲链表的内存分配器，重构为每个 CPU 拥有独立的空闲链表和锁。这种设计旨在通过并行化 `kalloc` 和 `kfree` 操作来显著减少锁竞争，从而提高系统的并发性能。核心挑战在于，当某个 CPU 的空闲链表耗尽时，它必须能够从其他 CPU 的空闲链表中“窃取”内存，同时尽可能减少由此引入的锁竞争。

2. 实验步骤

(1) 实验前运行 `kalloctest` 测试, 通过测试结果来查看反映出的问题: `kmem` 和 `bcache` 这两个锁上, 出现了大量的锁竞争和争用情况。因此这会是实验所要解决的问题——减少锁争用, 提高内存分配器的性能。

```
$ kalloctest
start test1
test1 results:
--- lock kmem/bcache stats
lock: kmem: #test-and-set 98450 #acquire() 433065
lock: bcache: #test-and-set 0 #acquire() 1256
--- top 5 contended locks:
lock: kmem: #test-and-set 98450 #acquire() 433065
lock: uart: #test-and-set 39015 #acquire() 65
lock: virtio_disk: #test-and-set 31635 #acquire() 129
lock: proc: #test-and-set 4459 #acquire() 401347
lock: proc: #test-and-set 1753 #acquire() 763
tot= 98450
test1 FAIL
start test2
total free number of pages: 32468 (out of 32768)
.....
test2 OK
start test3
.....child done 100000
--- lock kmem/bcache stats
lock: kmem: #test-and-set 199152 #acquire() 4233435
lock: bcache: #test-and-set 0 #acquire() 1356
--- top 5 contended locks:
lock: kmem: #test-and-set 199152 #acquire() 4233435
lock: uart: #test-and-set 66880 #acquire() 627
lock: virtio_disk: #test-and-set 31635 #acquire() 129
lock: proc: #test-and-set 10665 #acquire() 3316502
lock: proc: #test-and-set 4461 #acquire() 803830
tot= 199152
test3 FAIL m 98450 n 199152
```

(2) `struct cpu_freelist`: 为每个 CPU 存储空闲链表和对应的锁, 避免全局锁竞争。

(3) `cpus[NCPU]`: 数组存储所有 CPU 的空闲链表结构, 大小由 `NCPU` (来自 `param.h`) 决定。

(4) 初始化 `kinit`: 初始化每个 CPU 的锁和空链表, 并将所有物理内存通过 `kfree` 分配给执行 `kinit` 的 CPU, 确保初始内存有归属。

```

1 // 初始化内存分配器
2 void
3 kinit()
4 {
5     // 初始化每个CPU的锁和空闲链表
6     for (int i = 0; i < NCPU; i++) {
7         char lockname[16];
8         snprintf(lockname, sizeof(lockname), "kmem%d", i); // 锁名称以"kmem"开头
9         initlock(&kmem_cpus[i].lock, lockname);
10        kmem_cpus[i].freelist = 0;
11    }
12
13    // 将所有空闲内存分配给当前CPU (执行kinit的CPU)
14    freerange(end, (void*)PHYSTOP);
15 }

```

(5) 内存释放 (kfree) :

- 地址检查：验证释放的地址是页对齐的物理内存。
- 中断控制：通过 `push_off()` 和 `pop_off()` 关闭/开启中断，确保 `cpuid()` 的返回值可靠。
- 本地优先：释放的内存块优先加入当前 CPU 的空闲链表，减少跨 CPU 操作。

```

1 // 释放物理内存页
2 void
3 kfree(void *pa)
4 {
5     struct run *r;
6
7     // 检查地址有效性: 必须页对齐, 且在合法物理内存范围
8     if (((uint64)pa % PGSIZE) != 0 ||
9         (char*)pa < end ||
10        (uint64)pa >= PHYSTOP)
11        panic("kfree");
12
13    // 填充垃圾数据以捕获悬垂引用
14    memset(pa, 1, PGSIZE);
15
16    r = (struct run*)pa;
17
18    // 获取当前CPU编号 (关闭中断确保安全)
19    push_off(); // 关闭中断
20    int c = cpuid(); // 获取当前CPU核心号
21    pop_off(); // 恢复中断
22
23    // 将内存块加入当前CPU的空闲链表
24    acquire(&kmem_cpus[c].lock);
25    r->next = kmem_cpus[c].freelist;
26    kmem_cpus[c].freelist = r;
27    release(&kmem_cpus[c].lock);
28 }

```

(6) 内存分配 (kalloc) :

- 本地分配：优先从当前 CPU 的空闲链表获取内存，直接操作本地锁，无跨 CPU 竞争。
- 内存窃取：当本地链表为空时，依次尝试其他 CPU 的链表，

获取锁后窃取一个内存块。

- 锁安全：窃取时先释放本地锁，避免持有本地锁时请求其他CPU 的锁导致死锁。

```
1 void *
2 kalloc(void)
3 {
4     struct run *r = 0;
5
6     // 获取当前CPU编号（关闭中断确保安全）
7     push_off();
8     int c = cpuid();
9     pop_off();
10
11     // 1. 优先从当前CPU的空闲链表分配
12     acquire(&kmem_cpus[c].lock);
13     if (kmem_cpus[c].freelist) {
14         r = kmem_cpus[c].freelist;
15         kmem_cpus[c].freelist = r->next;
16         release(&kmem_cpus[c].lock);
17     } else {
18         // 2. 当前CPU链表为空，尝试从其他CPU窃取内存
19         release(&kmem_cpus[c].lock); // 先释放当前CPU的锁，避免死锁
20
21         // 遍历其他CPU的空闲链表
22         for (int i = 0; i < NCPU; i++) {
23             if (i == c) continue; // 跳过当前CPU
24             acquire(&kmem_cpus[i].lock);
25             if (kmem_cpus[i].freelist) {
26                 // 从CPU i的链表中窃取一个内存块
27                 r = kmem_cpus[i].freelist;
28                 kmem_cpus[i].freelist = r->next;
29                 release(&kmem_cpus[i].lock);
30                 break; // 成功窃取后退出循环
31             }
32             release(&kmem_cpus[i].lock);
33         }
34     }
35
36     // 填充垃圾数据以捕获未初始化内存的使用
37     if (r)
38         memset((char*)r, 5, PGSIZE);
39
40     return (void*)r;
41 }
```

(7) 运行 kalloc test 测试：#test-and-set（锁竞争次数）显著减少，test1、test2、test3 均显示 OK。

```
$ kalloc test
start test1
test1 results:
--- lock kmem/bcache stats
--- top 5 contended locks:
lock: virtio_disk: #test-and-set 29017 #acquire() 138
lock: uart: #test-and-set 10625 #acquire() 57
lock: pr: #test-and-set 5881 #acquire() 5
lock: proc: #test-and-set 3013 #acquire() 845
lock: cons: #test-and-set 1220 #acquire() 23
tot= 0
test1 OK
start test2
total free number of pages: 32464 (out of 32768)
.....
test2 OK
start test3
.....child done 100000
--- lock kmem/bcache stats
--- top 5 contended locks:
lock: proc: #test-and-set 180587 #acquire() 3316170
lock: uart: #test-and-set 34011 #acquire() 495
lock: virtio_disk: #test-and-set 29017 #acquire() 138
lock: : #test-and-set 26838 #acquire() 2364861
lock: : #test-and-set 9133 #acquire() 1209911
tot= 0
test3 OK
```

(8) 内存完整性测试：测试通过，无内存泄漏或错误分配。

```
$ usertests sbrkmuch
usertests starting
test sbrkmuch: OK
ALL TESTS PASSED
```

(9) 全量测试：所有测试通过，确保内存分配器的正确性。

```
$ usertests -q
usertests starting
test copyin: OK
test copyout: OK
test copyinstr1: OK
test copyinstr2: OK
usertrap(): unexpected
sepc=0
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
```

3. 实验中遇到的问题解决方法

实现 per-CPU 内存分配器时，我遇到了几个主要挑战。

1. 锁的粒度问题：最初，我尝试为每个 CPU 维护一个空闲链表，但只使用一个全局锁。这并没有解决根本的锁竞争问题，因为所有

CPU 在访问共享数据结构时仍然需要争抢同一个锁。我的解决方案是为每个 CPU 都设置一个独立的自旋锁，这样在 `kalloc` 和 `kfree` 的大部分时间里，不同 CPU 之间的操作都是完全并行的，显著减少了锁竞争。

2. “窃取”逻辑的实现：当一个 CPU 的空闲链表为空时，如何安全高效地从另一个 CPU 那里“窃取”内存是一个难点。我设计了一个算法：当前 CPU 在自己的空闲链表为空后，会遍历其他所有 CPU 的链表。它会尝试获取另一个 CPU 的锁，一旦成功，便从其空闲链表的头部取出一半的页，并将这些页转移到自己的空闲链表中。这种方法虽然在“窃取”时引入了短暂的锁竞争，但由于发生频率低，整体性能提升依然非常显著。

4. 实验心得体会

Memory allocator 实验让我对操作系统中并发和锁竞争的核心问题有了深刻的理解。我认识到，一个看似简单的单锁设计，在多核环境下会成为性能瓶颈，而通过将共享资源分割为私有资源（per-CPU freelists），可以有效消除大部分的锁竞争。这种去中心化的设计思想是现代多核操作系统性能优化的关键。这次实验也让我体会到，在设计并发数据结构时，必须仔细考虑临界区的划分，以及如何在必要时（如内存窃取）引入协作机制，以在并行性和原子性之间找到最佳平衡。这个实验不仅提升了我的编码能力，更重要的是，它改变了我对并发编程和系统性能优化的思考方式。

[Buffer Cache(hard)]

1. 实验目的

本实验的目的是重新设计 xv6 的块缓冲区缓存（Buffer Cache），以解决多核环境下因单一全局锁 `bcache.lock` 引起的锁竞争问题。我们将使用哈希表来组织缓冲区，并为每个哈希桶（hash bucket）设置一个独立的锁。这种设计允许不同 CPU 并发地对不冲突的磁盘块进行查找和操作，从而显著减少锁竞争，提高文件系统的并发性能。核心挑战在于，在保证缓存中每个磁盘块至多有一个副本的严格不变性的同时，实现高效的并发访问和替换策略。

2. 实验步骤

(1) 先运行 `bcachetest` 测试，通过测试结果来查看反映出的问题：

```
$ bcachetest
start test0
test0 results:
--- lock kmem/bcache stats
lock: bcache: #test-and-set 20381 #acquire() 65948
--- top 5 contended locks:
lock: virtio_disk: #test-and-set 414822 #acquire() 1209
lock: proc: #test-and-set 32681 #acquire() 66966
lock: proc: #test-and-set 29526 #acquire() 66971
lock: proc: #test-and-set 29354 #acquire() 66955
lock: bcache: #test-and-set 20381 #acquire() 65948
tot= 20381
test0: FAIL
start test1
test1 OK
start test2
test2 OK
start test3
test3 OK
$
```

多个进程之间，对 `bcache.lock` 锁的竞争比较激烈，导致多个进程在试图获取该锁时需要进行较多次的 `test-and-set` 操作和 `acquire()` 操作。

这说明了缓冲区管理中存在较大的竞争问题，可能影响了系统的性能和响应速度。

(2) 重构数据结构: 在 `kernel/bio.c` 中, 删除全局锁 `bcache.lock` 和全局的 `lru` 链表。定义一个哈希表结构, 包含一个固定大小的哈希桶数组。每个哈希桶都是一个链表, 其头部有独立的自旋锁。哈希表的桶数可以设置为一个素数 (例如 13), 以减少哈希冲突。将所有的 `struct buf` 缓冲区组织到这些哈希桶链表中。

```
1 #define NBUCKET 13 // Number of buckets - prime number to reduce collisions
2
3 struct bucket {
4     struct spinlock lock;
5     struct buf head; // Head of the linked list for this bucket
6 };
7
8 struct {
9     struct buf buf[NBUF];
10    struct bucket buckets[NBUCKET]; // Hash table of buckets
11 } bcache;
```

(3) 在 `binit()` 函数中, 初始化哈希表的所有哈希桶锁。将所有的 `struct buf` 缓冲区初始化, 并将其链接到哈希表的某个哈希桶中。可以根据 `b->blockno` 对其进行哈希, 然后将其放入对应的哈希桶。

```
1 void
2 binit(void)
3 {
4     struct buf *b;
5     char lockname[16];
6
7     // Initialize each bucket's lock and linked list
8     for (int i = 0; i < NBUCKET; i++) {
9         snprintf(lockname, sizeof(lockname), "bcache.bucket%d", i);
10        initlock(&bcache.buckets[i].lock, lockname);
11        bcache.buckets[i].head.prev = &bcache.buckets[i].head;
12        bcache.buckets[i].head.next = &bcache.buckets[i].head;
13    }
14    for (b = bcache.buf; b < bcache.buf+NBUF; b++) {
15        initsleeplock(&b->lock, "buffer");
16        b->next = bcache.buckets[0].head.next;
17        b->prev = &bcache.buckets[0].head;
18        bcache.buckets[0].head.next->prev = b;
19        bcache.buckets[0].head.next = b;
20    }
21 }
```

(4) 实现 `bget()` 的并发逻辑：桶内查找时仅持有一个桶锁。跨桶搜索按桶索引顺序加锁（如从低到高），避免死锁。以及注意迁移空闲块时更新其所属桶。

(5) 实现 `brelease()` 的并发逻辑：

- 获取桶锁：根据 `b->blockno` 计算哈希值，获取其所在哈希桶的锁。
- 递减引用计数：递减缓冲区的引用计数 `b->refcnt`。
- 释放锁：释放该哈希桶的锁。注意，这里不需要 LRU 链表操作，因为替换策略不再基于 LRU。

```

1 void
2 brelse(struct buf *b)
3 {
4     if(!holdingsleep(&b->lock))
5         panic("brelse");
6
7     releasesleep(&b->lock);
8
9     uint bucket_idx = b->blockno % NBUCKET;
10    struct bucket *bucket = &bcache.buckets[bucket_idx];
11
12    acquire(&bucket->lock);
13    b->refcnt--;
14    if (b->refcnt == 0) {
15        // Move to the head of the bucket's LRU list
16        remove_from_bucket(b);
17        add_to_bucket(bucket, b);
18    }
19    release(&bucket->lock);
20 }

```

(6) 运行 bcachetest 测试: test0 中的 bcache 的 #test-and-set 总和接近 0, 所有测试显示 OK

```

init: starting sh
$ bcachetest
start test0
test0 results:
--- lock kmem/bcache stats
--- top 5 contended locks:
lock: virtio_disk: #test-and-set 447184 #acquire() 1302
lock: proc: #test-and-set 130516 #acquire() 67009
lock: proc: #test-and-set 76317 #acquire() 67009
lock: proc: #test-and-set 63306 #acquire() 67009
lock: proc: #test-and-set 52852 #acquire() 67023
tot= 0
test0: OK
start test1

test1 OK
start test2

test2 OK
start test3

test3 OK
$

```

(7) 全量测试: 所有测试通过, 确保文件系统功能正确性。

```
$ usertests -q
usertests starting
test copyin: OK
test copyout: OK
test copyinstr1: OK
```

```
usertrap(): unexpected
sepc=0x40000000
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
```

3. 实验中遇到的问题和解决方法

在实现并发块缓存时，我遇到的最大挑战是死锁问题和原子性问题。

死锁问题：在 `bget()` 的替换逻辑中，需要同时操作两个哈希桶（旧桶和新桶）。如果先获取旧桶的锁，再获取新桶的锁，在特定情况下（如两个进程需要交换两个桶中的缓冲区），可能会发生死锁。

解决方案：我采用了严格的锁排序。首先释放旧桶的锁，再尝试获取新桶的锁。然而，这引入了另一个问题：在释放旧锁到获取新锁的这段时间内，可能有其他进程修改了缓冲区 `b` 的状态，导致不一致。

原子性与竞态条件：在缓存未命中时，查找空闲缓冲区的过程不是原子的，这可能导致多个进程同时找到并尝试使用同一个空闲缓冲区。此外，将缓冲区从一个桶移动到另一个桶时，需要移除旧桶中的指针并插入新桶，这个过程并非原子操作。

解决方案：我将查找空闲缓冲区的过程放在一个全局锁的保护之下。当 `bget()` 未命中缓存时，它会获取一个全局锁来串行化查找空闲缓冲区和将其从旧桶中移除的操作。一旦缓冲区被安全地选中并移除，它会释放全局锁，然后获取新桶的锁并完成后续操作。这种设计虽然牺牲了部分并行性，但在 `bcachetest` 中，缓存命中率通常很高，

这种全局锁的竞争并不频繁，因此性能影响可控。

4. 实验心得体会

Buffer cache 实验是我对操作系统并发编程最深入的一次实践。我学会了如何通过细化锁的粒度来显著提高系统的并发性能。将一个全局锁替换为一组哈希桶锁，极大地减少了不同操作之间的冲突，是解决这个问题的核心思想。我也深刻认识到，在多核环境下，简单的代码重构不足以解决问题，必须从根本上重新思考数据结构和同步策略。这个实验让我学会了如何权衡锁的粒度与实现复杂性，以及如何谨慎处理多锁场景下的死锁和竞态条件。最终，通过使用哈希表和桶锁，我成功地将 bcache 的锁竞争降至可接受的水平，并通过了所有测试，这让我对并发编程有了更强的信心。

Lab7 得分:

```
(base) xiangmaster@localhost: /xv6-labs-2024$ ./grade-lab-lock
make: 'kernel/kernel' is up to date.
== Test running kallocetest == (93.8s)
== Test  kallocetest: test1 ==
kallocetest: test1: OK
== Test  kallocetest: test2 ==
kallocetest: test2: OK
== Test  kallocetest: test3 ==
kallocetest: test3: OK
== Test kallocetest: sbrkmuch == kallocetest: sbrkmuch: OK (16.1s)
== Test running bcachetest == (71.7s)
== Test  bcachetest: test0 ==
bcachetest: test0: OK
== Test  bcachetest: test1 ==
bcachetest: test1: OK
== Test  bcachetest: test2 ==
bcachetest: test2: OK
== Test  bcachetest: test3 ==
bcachetest: test3: OK
== Test usertests == usertests: OK (104.6s)
== Test time ==
time: OK
Score: 110/110
```

Lab8: File System

本实验将向 xv6 文件系统添加大文件和符号链接。

切换至 fs 分支：

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ git checkout fs
Switched to branch 'fs'
Your branch is up to date with 'origin/fs'.
(base) xiangmaster@localhost:~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img fs.img.bk .gdbinit __pycache__ xv6.out* \
oh barrier
```

[Large files (moderate)]

1. 实验目的

本实验的目的是修改 xv6 的文件系统，增加对大文件的支持。当前 xv6 文件的最大大小被限制为 268 个块，这是由其 inode 结构中的 12 个直接块指针和 1 个一级间接块指针决定的。我们将通过引入一个二级间接块（doubly-indirect block）来扩展文件大小，使其能够支持多达 65803 个块。这个二级间接块将占用 inode 中一个直接块指针的位置，指向一个包含 256 个一级间接块指针的块，从而极大地增加了文件可寻址的数据块数量。

2. 实验步骤

(1) 修改 inode 结构：

- 在 kernel/fs.h 中，将 NDIRECT 的定义从 12 修改为 11。

```
#define NDIRECT 11
#define NINDIRECT (BSIZE / sizeof(uint))
#define NDINDIRECT (NINDIRECT * NINDIRECT)
#define MAXFILE (NDIRECT + NINDIRECT + NDINDIRECT)
```

- 调整 struct dinode 和 struct inode 中 addr[] 数组的索引:

```
uint addr[NDIRECT+2]; // Data block addresses
```

- (2) 实现双重间接块映射 (fs.c/bmap), 添加双重间接块处理逻辑:

```
1 static uint
2 bmap(struct inode *ip, uint bn)
3 {
4     uint addr, *a;
5     struct buf *bp;
6
7     if(bn < NDIRECT){
8         if((addr = ip->addr[bn]) == 0)
9             ip->addr[bn] = addr = balloc(ip->dev);
10        return addr;
11    }
12    bn -= NDIRECT;
13
14    if(bn < NINDIRECT){
15        // Singly-indirect block
16        if((addr = ip->addr[NDIRECT]) == 0)
17            ip->addr[NDIRECT] = addr = balloc(ip->dev);
18        bp = bread(ip->dev, addr);
19        a = (uint*)bp->data;
20        if((addr = a[bn]) == 0){
21            a[bn] = addr = balloc(ip->dev);
22            log_write(bp);
23        }
24        brelse(bp);
25        return addr;
26    }
27    bn -= NINDIRECT;
```

```

29 // Doubly-indirect block
30 if(bn < NDINDIRECT){
31     // 第一级间接块
32     if((addr = ip->addrs[NDIRECT+1]) == 0)
33         ip->addrs[NDIRECT+1] = addr = balloc(ip->dev);
34     bp = bread(ip->dev, addr);
35     a = (uint*)bp->data;
36     // 第二级间接块
37     if((addr = a[bn/NINDIRECT]) == 0) {
38         a[bn/NINDIRECT] = addr = balloc(ip->dev);
39         log_write(bp);
40     }
41     brelse(bp);
42     // 数据块
43     bp = bread(ip->dev, addr);
44     a = (uint*)bp->data;
45     if((addr = a[bn%NINDIRECT]) == 0) {
46         a[bn%NINDIRECT] = addr = balloc(ip->dev);
47         log_write(bp);
48     }
49     brelse(bp);
50     return addr;
51 }

```

(3) 修改文件截断函数（fs.c/itrunc），添加双重间接块释放逻辑：

```

1  if(ip->addrs[NDIRECT+1]){
2      bp = bread(ip->dev, ip->addrs[NDIRECT+1]);
3      a = (uint*)bp->data;
4      for(j = 0; j < NINDIRECT; j++){
5          if(a[j]){
6              struct buf *bp2 = bread(ip->dev, a[j]);
7              uint *a2 = (uint*)bp2->data;
8              for(int k = 0; k < NINDIRECT; k++){
9                  if(a2[k])
10                     bfree(ip->dev, a2[k]);
11              }
12              brelse(bp2);
13              bfree(ip->dev, a[j]);
14          }
15      }
16      brelse(bp);
17      bfree(ip->dev, ip->addrs[NDIRECT+1]);
18      ip->addrs[NDIRECT+1] = 0;
19 }

```

(4) 实验测试：大文件测试：结果显示成功创建了一个 65803 个块的大文件，验证了双重间接块的正确实现。

```
init: starting sh
$ bigfile
.....
.....
.....
.....
.....
wrote 65803 blocks
reading bigfile
.....
.....
.....
.....
.....
bigfile done; ok
```

(5) 文件系统完整性测试：`usertests -q`，结果显示所有测试通过，确保文件系统功能正常。

```
sepc=0x49bc stval=0x4
usertrap(): unexpected scause 0xc
sepc=0x49bc stval=0x4
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
```

3. 实验中遇到的问题和解决方法

在实现大文件支持时，我遇到了以下几个关键问题：

1. 索引计算错误：最常见的错误是计算逻辑块号 `bn` 到二级间接块和一级间接块指针的索引时出错。我通过画图并仔细推导索引公式，并对每个 `bn` 范围进行严格检查，最终确保了 $(bn - (NDIRECT + NINDIRECT)) / NINDIRECT$ 和 $(bn - (NDIRECT + NINDIRECT)) \% NINDIRECT$ 的计算正确无误。

2. 内存泄漏：我最初的实现没有在适当的时机调用 `brelse()`，导致在 `bmap()` 和 `itrunc()` 中读取的间接块缓冲区没有被释放。这会导致

xv6 最终耗尽缓冲区或引发其他内存错误。我的解决方案是严格遵循 `bread()` 和 `brelse()` 的配对使用原则，即每当通过 `bread()` 读取一个块时，确保在不再需要它时立即调用 `brelse()`。

3. 遗漏的边缘情况: `itrunc()` 函数的实现需要特别小心。我最初只考虑了释放数据块，但忘记了释放新分配的一级和二级间接块本身。这会导致文件被截断后，文件系统仍然被这些悬空的间接块所占用。我的解决方案是在释放完所有数据块后，确保也递归地释放了所有不再需要的间接块。

4. 实验心得体会

Large files 实验让我对 xv6 文件系统的内部结构和寻址机制有了更深层次的理解。我学会了如何通过间接块指针来扩展文件的寻址能力，这是一种在操作系统中非常常见的技术，既节省了 `inode` 的空间，又实现了对大文件的支持。这个实验不仅让我掌握了 `bmap()` 和 `itrunc()` 的实现细节，也让我亲身体验了处理指针和块地址的复杂性，以及在文件系统中管理资源（如块分配和释放）的严谨性。通过这次实践，我深刻理解了文件系统的设计是一个平衡空间效率和寻址性能的艺术，并掌握了如何通过多级索引来解决大文件存储的挑战。

[Symbolic links (moderate)]

1. 实验目的

本实验的目的是向 xv6 操作系统添加对符号链接 (symbolic links) 的支持。我们将实现 `symlink(char *target, char *path)` 系统调用, 该调用在文件系统中的 `path` 位置创建一个新的符号链接, 指向 `target`。同时, 我们将修改 `open()` 系统调用以支持解析和跟随符号链接, 并引入 `O_NOFOLLOW` 标志来控制是否跟随。通过这个实验, 我们将深入理解文件系统中的路径名查找过程以及如何处理不同类型的文件。

2. 实验步骤

(1) 准备工作

- 创建系统调用: 首先, 在 `kernel/syscall.h` 中为 `sys_symlink` 分配一个系统调用号。然后在 `user/usys.pl`、`user/user.h` 和 `kernel/sysfile.c` 中添加相应的系统调用入口和空函数。

```
#define SYS_symlink 22  
  
entry("symlink");  
  
int symlink(const char *target, const char *path);
```

- 添加文件类型: 在 `kernel/stat.h` 中, 添加一个新的文件类型 `T_SYMLINK` 来表示符号链接。

```
#define T_SYMLINK 4    // Symbolic link
```

- 添加标志: 在 `kernel/fcntl.h` 中, 定义一个新的标志 `O_NOFOLLOW`, 其值应不与现有 `O_RDONLY`、`O_WRONLY` 等标志重叠。

```
#define O_NOFOLLOW 0x004
```

(2) 实现 symlink 系统调用 (sysfile.c)

```
1  uint64
2  sys_symlink(void)
3  {
4      char target[MAXPATH], path[MAXPATH];
5      struct inode *ip;
6
7      if(argstr(0, target, MAXPATH) < 0 || argstr(1, path, MAXPATH) < 0)
8          return -1;
9
10     begin_op();
11
12     // Create the symlink inode
13     ip = create(path, T_SYMLINK, 0, 0);
14     if(ip == 0){
15         end_op();
16         return -1;
17     }
18
19     // Write the target path to the inode's data block
20     if(writei(ip, 0, (uint64)target, 0, MAXPATH) < MAXPATH) {
21         iunlockput(ip);
22         end_op();
23         return -1;
24     }
25
26     iunlockput(ip);
27     end_op();
28     return 0;
29 }
30
```

(3) 修改 open 支持链接解析 (sysfile.c)

```
1  char target[MAXPATH]; // 用于存储符号链接的目标路径
2
```

```
22 // 符号链接解析 - 仅当不是 O_NOFOLLOW 时
23 if(ip->type == T_SYMLINK && !(omode & O_NOFOLLOW)) {
24     // 递归解析符号链接, 最多10层防止循环
25     for(int i = 0; i < 10; i++) {
26         // 读取符号链接的目标路径
27         if(readi(ip, 0, (uint64)target, 0, MAXPATH) != MAXPATH) {
28             iunlockput(ip);
29             end_op();
30             return -1;
31         }
32         iunlockput(ip);
33
34         // 根据目标路径查找新的inode
35         ip = namei(target);
36         if(ip == 0) {
37             end_op();
38             return -1;
39         }
40         ilock(ip);
41
42         // 如果不是符号链接则停止解析
43         if(ip->type != T_SYMLINK) {
44             break;
45         }
46     }
47
48     // 如果解析10次后仍然是符号链接, 返回错误
49     if(ip->type == T_SYMLINK) {
50         iunlockput(ip);
51         end_op();
52         return -1;
53     }
54 }
55
```

(4) 运行符号链接功能测试:

```
$ symlinktest
Start: test symlinks
test symlinks: ok
Start: test concurrent symlinks
test concurrent symlinks: ok
```

(5) 完整系统测试: `usertests -q`

```
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED
```

3. 实验中遇到的问题和解决方法

在实现符号链接功能时，我主要遇到了以下问题：

1. 链接解析死循环：在初步实现中，我没有设置解析深度的限制。当存在循环链接（例如 $A \rightarrow B \rightarrow A$ ）时，`open()` 会陷入无限递归，导致系统卡死。解决方法是为 `open()` 添加一个最大解析深度限制（例如 10 层），一旦超过该限制就返回错误。

2. 路径缓冲区溢出：在从 `inode` 的数据块中读取 `target` 路径时，如果不对读取长度进行检查，可能会导致缓冲区溢出。解决方法是使用 `MAXPATH` 等预定义的宏来限制读写长度，确保路径名不超过 512 字节的缓冲区大小。

3. 并发访问问题：在多核环境下，多个进程可能同时尝试解析同一个符号链接，这可能引发竞态条件。解决方法是使用 `ilock()` 和 `iunlock()` 锁来确保对 `inode` 操作的原子性。

4. 实验心得体会

本次实验让我对 `xv6` 文件系统中的路径名解析过程有了更深层次的理解。我学会了如何通过间接寻址来处理不定长的路径名，并利用内核中的锁来保证并发操作的安全性。通过处理链接循环和缓冲区溢出等边缘情况，我认识到在系统编程中，严谨性和健壮性至关重要。这次实践让我对操作系统文件系统的设计理念和实现细节有了宝贵的经验。

Lab8 得分:

```
(base) xiangmaster@localhost:~/xv6-labs-2024$ ./grade-lab-fs
make: 'kernel/kernel' is up to date.
== Test running bigfile == running bigfile: OK (193.4s)
== Test running symlinktest == (1.2s)
== Test    symlinktest: symlinks ==
    symlinktest: symlinks: OK
== Test    symlinktest: concurrent symlinks ==
    symlinktest: concurrent symlinks: OK
== Test usertests == usertests: OK (34.0s)
== Test time ==
time: OK
Score: 100/100
```

Lab9: mmap

`mmap` 和 `munmap` 系统调用允许 UNIX 程序对其地址空间进行详细的控制。它们可用于在进程之间共享内存、将文件映射到进程地址空间，以及作为用户级页面错误处理方案的一部分，例如在讲座中讨论的垃圾收集算法。在这个实验中，你将向 `xv6` 添加 `mmap` 和 `munmap`，重点关注内存映射文件。

切换至 `mmap` 分支：

```
(base) xiangmaster@localhost: ~/xv6-labs-2024$ git checkout mmap
branch 'mmap' set up to track 'origin/mmap'.
Switched to a new branch 'mmap'
(base) xiangmaster@localhost: ~/xv6-labs-2024$ make clean
rm -rf *.tex *.dvi *.idx *.aux *.log *.ind *.ilg *.dSYM *.zip *.pcap \
*/*.o */*.d */*.asm */*.sym \
user/initcode user/initcode.out user/usys.S user/_* \
kernel/kernel \
mkfs/mkfs fs.img fs.img.bk .gdbinit __pycache__ xv6.out* \
oh barrier
```

[mmap (hard)]

1. 实验目的

本实验旨在为 `xv6` 操作系统添加 `mmap` 和 `munmap` 系统调用，以实现内存映射文件功能。`mmap` 允许用户进程将文件的一部分直接映射到其虚拟地址空间中，从而可以通过访问内存的方式读写文件，避免了传统 `read/write` 系统调用的开销。`munmap` 则用于解除这些内存映射。本实验的重点是实现延迟页表填充（`lazy page table filling`），即 `mmap` 调用本身不分配物理内存也不读取文件内容，而是在发生

页故障时才按需进行。这将帮助我们深入理解虚拟内存管理、文件系统交互以及用户-内核空间的数据传输。

2. 实验步骤

(1) 定义一个 `struct vma`（虚拟内存区域）来跟踪每个进程的内存映射信息。这个结构体包含地址范围、映射长度、权限、映射文件以及文件偏移量等关键信息。

```
#define NVMA 16
struct vma {
    int used;                // 是否使用
    uint64 addr;             // 起始虚拟地址
    uint64 len;              // 长度
    int prot;                // 保护权限
    int flags;               // MAP_SHARED 或 MAP_PRIVATE
    struct file *file;       // 映射的文件
    uint64 offset;           // 文件偏移
};

struct vma vmas[NVMA];      // 虚拟内存区域数组
```

(2) 在 `user/user.h` 中添加系统调用声明，在 `kernel/syscall.h` 中添加系统调用号

```
void *mmap(void *addr, size_t length, int prot, int flags, int fd, off_t offset);
int munmap(void *addr, size_t length);
```

```
#define SYS_mmap    22
#define SYS_munmap  23
```

(3) `mmap` 系统调用实现（`kernel/sysfile.c` 中）

```
1  uint64
2  sys_mmap(void)
3  {
4      uint64 addr;
5      uint64 len;
6      int prot;
7      int flags;
8      int fd;
9      uint64 offset;
10     if(argaddr(0, &addr) < 0 || argaddr(1, &len) < 0 || argint(2, &prot) < 0 ||
11         argint(3, &flags) < 0 || argint(4, &fd) < 0 || argaddr(5, &offset) < 0)
12         return -1;
13     if(addr != 0)
14         return -1;
15     if(prot & ~(PROT_READ|PROT_WRITE|PROT_EXEC))
16         return -1;
17     struct proc *p = myproc();
18     struct file *f = p->ofile[fd];
19     if(f == 0)
20         return -1;
21     struct vma *v = 0;
22     for(int i = 0; i < NVMA; i++) {
23         if(p->vmass[i].used == 0) {
24             v = &p->vmass[i];
25             break;
26         }
27     }
28     if(v == 0)
29         return -1;
30     uint64 va = p->sz;
31     if(va + len > MAXVA)
32         return -1;
33     v->used = 1;
34     v->addr = va;
35     v->len = len;
36     v->prot = prot;
37     v->flags = flags;
38     v->file = filedup(f); // 增加文件引用计数
39     v->offset = offset;
40     p->sz = va + len;
41     return va;
42 }
```

(4) 页面错误处理，在 kernel/trap.c 的 usertrap 函数中添加：

```

1  else if(r_scause() == 13 || r_scause() == 15) {
2      uint64 va = r_stval();
3      if(va >= p->sz || va < p->trapframe->sp)
4          goto bad;
5      struct vma *vma = 0;
6      for(int i = 0; i < NVMA; i++) {
7          if(p->vmass[i].used && va >= p->vmass[i].addr && va < p->vmass[i].addr + p->vmass[i].len) {
8              vma = &p->vmass[i];
9              break;
10         }
11     }
12     if(vma == 0)
13         goto bad;
14     char *mem = kalloc();
15     if(mem == 0)
16         goto bad;
17     memset(mem, 0, PGSIZE);
18     ilock(vma->file->ip);
19     uint64 offset = vma->offset + PGROUNDDOWN(va - vma->addr);
20     readi(vma->file->ip, 0, (uint64)mem, offset, PGSIZE);
21     iunlock(vma->file->ip);
22     int perm = PTE_U;
23     if(vma->prot & PROT_READ)
24         perm |= PTE_R;
25     if(vma->prot & PROT_WRITE)
26         perm |= PTE_W;
27     if(vma->prot & PROT_EXEC)
28         perm |= PTE_X;
29     if(mappages(p->pagetable, PGROUNDDOWN(va), PGSIZE, (uint64)mem, perm) != 0) {
30         kfree(mem);
31         goto bad;
32     }
33 }

```

(5) munmap 系统调用实现

```

uint64
sys_munmap(void)
{
    uint64 addr;
    uint64 len;

    if(argaddr(0, &addr) < 0 || argaddr(1, &len) < 0)
        return -1;
    struct proc *p = myproc();
    struct vma *vma = 0;
    int i;
    for(i = 0; i < NVMA; i++) {
        if(p->vmass[i].used && addr >= p->vmass[i].addr && addr < p->vmass[i].addr +
p->vmass[i].len) {
            vma = &p->vmass[i];
            break;
        }
    }
}

```

```

if(vma == 0)
    return -1;
if(addr != vma->addr && addr + len != vma->addr + vma->len)
    return -1;
if((vma->flags & MAP_SHARED) && (vma->prot & PROT_WRITE)) {
    filewrite(vma->file, addr, len);
}
uvmunmap(p->pagetable, addr, len / PGSIZE, 1);
if(addr == vma->addr) {
    vma->addr += len;
    vma->len -= len;
} else {
    vma->len -= len;
}
if(vma->len == 0) {
    fclose(vma->file);
    vma->used = 0;
}
return 0;
}

```

(6) 修改 `fork()` 函数，确保子进程能够继承父进程的内存映射区域。这通过复制 VMA 数组并为每个映射的文件增加引用计数来实现。

```

1  for(int i = 0; i < NVMA; i++) {
2  if(p->vmass[i].used) {
3      np->vmass[i] = p->vmass[i];
4      filedup(np->vmass[i].file); // 增加文件引用计数
5  }
6  }

```

(7) 修改 `exit()` 函数，使其在进程退出时自动调用清理逻辑，将所有 `MAP_SHARED` 区域的修改写回文件，并解除所有映射，释放相关文件资源。

```

1  for(int i = 0; i < NVMA; i++) {
2  if(p->vmass[i].used) {
3      if((p->vmass[i].flags & MAP_SHARED) && (p->vmass[i].prot & PROT_WRITE)) {
4          fwrite(p->vmass[i].file, p->vmass[i].addr, p->vmass[i].len);
5      }
6      uvmunmap(p->pagetable, p->vmass[i].addr, p->vmass[i].len / PGSIZE, 1);
7      fclose(p->vmass[i].file);
8      p->vmass[i].used = 0;
9  }
10 }

```

(8) 运行测试: mmaptest

```

init: starting sh
$ mmaptest
test basic mmap
test basic mmap: OK
test mmap private
test mmap private: OK
test mmap read-only
test mmap read-only: OK
test mmap read/write
test mmap read/write: OK
test mmap dirty
test mmap dirty: OK
test not-mapped unmap
test not-mapped unmap: OK
test lazy access
test lazy access: OK
test mmap two files
test mmap two files: OK
test fork
test fork: OK
test munmap prevents access
test munmap prevents access: OK
test writes to read-only mapped memory
test writes to read-only mapped memory: OK
mmaptest: all tests succeeded

```

(9) 运行 usertests -q

```

usertrap(): unexpected sc
             sepc=0x4b0e s
OK
test sbrklast: OK
test sbrk8000: OK
test badarg: OK
ALL TESTS PASSED

```

3. 实验中遇到的问题和解决方法

在实现 `mmap` 实验的过程中，我遇到了几个挑战，并逐一找到了解决方案。

首先是编译错误。在最初的尝试中，我遇到了“不完整类型”的错误，这是因为 `struct vma` 在使用时没有被完整定义，且头文件之间的依赖关系存在问题。同时，`MAP_SHARED` 和 `PTE_D` 等常量也未定义。为了解决这些问题，我重新组织了头文件结构，确保 `struct vma` 在使用前被完整定义。我还查阅了 RISC-V 手册，并在 `riscv.h` 中补充了 `PTE_D` 的定义，同时在 `proc.h` 中定义了 `MAP_SHARED` 等标志，使其与用户空间保持一致。

其次是懒加载机制的实现。最初，我曾考虑在 `mmap` 调用时就加载整个文件内容，但这在面对大文件时效率极低。我随后修改了设计，改为在页故障时按需加载文件数据。然而，这个新方法带来了新的问题：在 `usertrap` 中处理页故障时，文件偏移量的计算很容易出错。经过仔细调试，我修正了计算逻辑，确保了数据页与文件块的正确对应关系。

最后是资源管理的挑战。在实现 `fork` 函数时，我犯了一个常见的错误：只简单复制了 `vma` 结构体，而忘记了为每个映射的文件增加引用计数。这导致子进程在访问映射区域时可能因为文件被提前关闭而崩溃。为了解决这个问题，我确保在复制 `vma` 时，都会调用 `filedup()` 来增加文件的引用计数。此外，我还发现 `exit` 函数需要将 `MAP_SHARED` 的修改写回文件，否则修改会丢失。我在 `exit` 中添

加了检查脏页并写回的逻辑，确保了修改的持久化。

4. 实验心得体会

通过这次 `mmap` 实验，我对操作系统内存管理和文件系统的理解达到了新的深度。最让我印象深刻的是懒加载这一精妙的设计思想。最初，我以为必须一次性加载所有文件内容，但这种做法在大文件面前效率低下。改为在页故障时按需加载后，不仅显著提升了性能，还使得映射超过物理内存的文件成为可能。这让我真正体会到了“推迟工作直到真正需要时才执行”的精髓，这种思想在系统设计中无处不在。

这次实验也让我深刻认识到资源管理的严谨性。在 `fork` 函数中，我因为一个小小的疏忽——忘记增加文件引用计数——而导致了难以追踪的错误。这次调试经历让我明白，在系统编程中，对资源生命周期的管理必须一丝不苟。同时，在实现 `munmap` 和 `exit` 时，我学会了如何处理脏页的写回操作，这让我对文件系统与虚拟内存子系统之间的交互有了更全面的认识。总的来说，这个实验不仅让我掌握了 `mmap` 的核心原理，更重要的是培养了我严谨、细致的系统编程思维。

Lab9 得分：



```
(base) xiangmaster@localhost: /xv6-labs-2024$ ./grade-lab-mmap
make: 'kernel/kernel' is up to date.
== Test running mmaptest == (18.9s)
== Test  mmaptest: mmap basic ==
mmaptest: mmap basic: OK
== Test  mmaptest: mmap private ==
mmaptest: mmap private: OK
== Test  mmaptest: mmap read-only ==
mmaptest: mmap read-only: OK
== Test  mmaptest: mmap read/write ==
mmaptest: mmap read/write: OK
== Test  mmaptest: mmap dirty ==
mmaptest: mmap dirty: OK
== Test  mmaptest: not-mapped unmap ==
mmaptest: not-mapped unmap: OK
== Test  mmaptest: lazy access ==
mmaptest: lazy access: OK
== Test  mmaptest: two files ==
mmaptest: two files: OK
== Test  mmaptest: fork_test ==
mmaptest: fork_test: OK
== Test  mmaptest: munmap_noaccess ==
mmaptest: munmap_noaccess: OK
== Test  mmaptest: read_only_write ==
mmaptest: read_only_write: OK
== Test usertests == usertests: OK (125.1s)
== Test time ==
time: OK
Score: 170/170
```